大数据分析在心理学的应用-补充

刘晓倩

中国科学院心理研究所计算网络心理实验室

科学基础：用户心理在网络行为中的映射

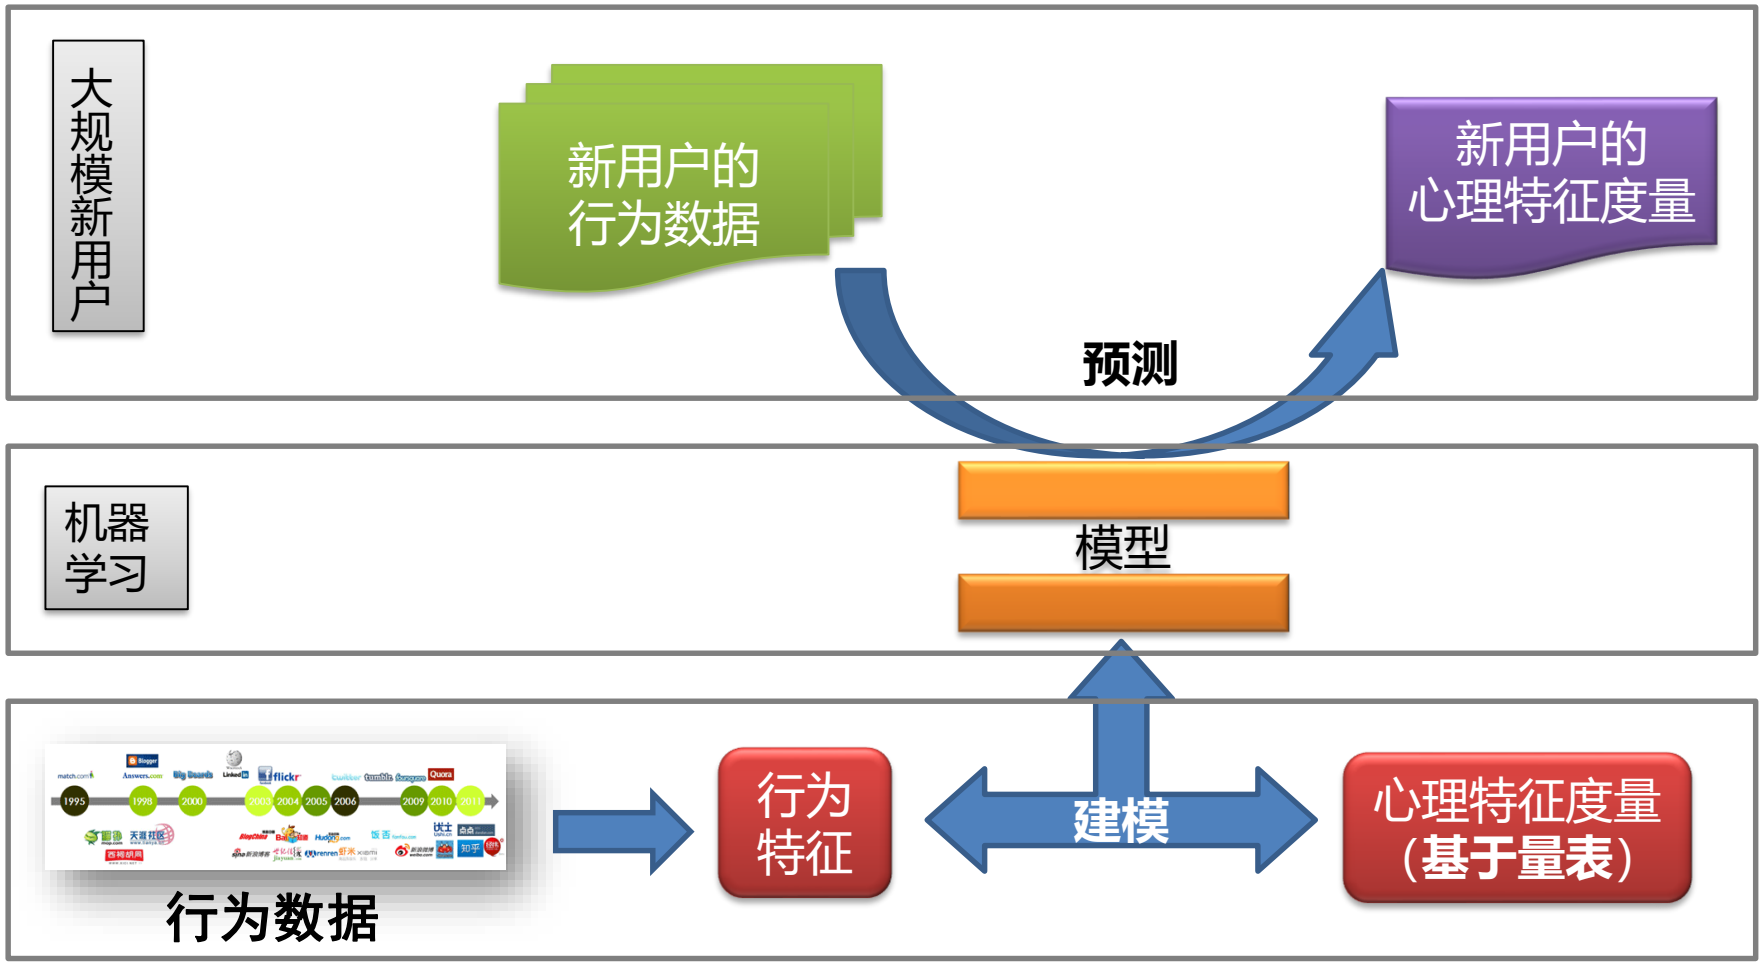
- 心理特征与在线行为之间的**相关分析** *[Schwartz, Seligman, et al. 2012]*

性别、年龄、外向型、宜人性、尽责性、神经质、开放性

社交网络用户语言LIWC词类

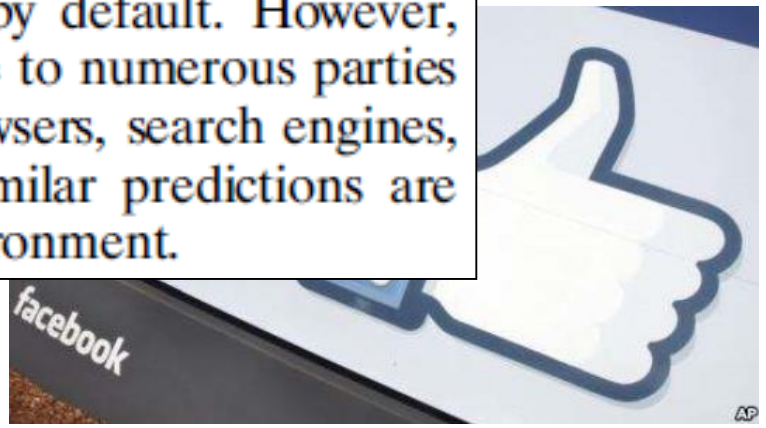
LIWC	Gender		Age		Extraversion		Agreeableness		Conscientious.		Neuroticism		Openness	
Category	[34] d	our β	[30] β	our β	[27] ρ	our β	[27] ρ	our β	[27] ρ	our β	[27] ρ	our β	[27] ρ	our β
Total function words	-	-0.04	-	0.16	-	-0.04	-	0.02	-	0.02	-	0.03	-	0.09
Total pronouns	0.36	0.07	-	-0.02	ns	ns	0.11	ns	ns	-0.03	ns	0.04	-0.21	0.07
Personal pronouns	-	0.14	-	-0.08	-	ns	-	ns	-	-0.04	-	0.04	-	0.05
1st pers singular	0.17	0.13	-0.14	-0.22	ns	ns	ns	-0.03	ns	-0.06	0.12	0.05	-0.16	0.05
1st pers plural	ns	ns	-0.13	0.21	0.11	0.03	0.18	0.05	ns	0.05	ns	-0.04	-0.1	ns
2nd person	-0.06	0.05	-	0.04	0.16	ns	ns	0.02	ns	ns	-0.15	ns	-0.12	0.02
3rd pers singular	-	0.09	-	0.15	-	ns	-	ns	-	ns	-	0.02	-	ns
3rd pers plural	-	-0.05	-	0.26	-	-0.06	-	-0.04	-	ns	-	0.02	-	0.03
3rd pers overall	0.2	-	-	-	ns	-	ns	-	ns	-	ns	-	ns	-
Impersonal pronouns	-	-0.09	-	0.11	-	-0.05	-	ns	-	ns	-	0.02	-	0.08
Articles	-0.24	-0.24	-	0.28	ns	-0.05	ns	ns	0.09	0.02	-0.11	-0.02	0.2	0.13
Common verbs	-	0.04	-	0.02	-	-0.03	-	ns	-	ns	-	0.04	-	0.03
Auxiliary verbs	-	0.02	-	0.08	-	-0.06	-	ns	-	ns	-	0.05	-	0.07
Past tense	0.12	-0.03	-0.16	ns	ns	-0.04	0.1	0.02	ns	-0.02	ns	ns	-0.16	ns
Present tense	0.18	0.08	0.04	ns	ns	ns	ns	ns	ns	ns	ns	0.04	-0.16	0.03
Future tense	ns	-0.07	0.14	0.09	ns	-0.05	ns	ns	ns	ns	ns	0.03	ns	0.05
Adverbs	-	0.05	-	-0.07	-	-0.04	-	ns	-	ns	-	0.05	-	0.04
Prepositions	-0.17	-0.13	-	0.27	ns	-0.04	ns	0.03	ns	0.06	ns	ns	0.17	0.06
Conjunctions	-	0.03	-	0.12	-	-0.02	-	0.02	-	0.02	-	0.02	-	0.06
Negations	0.11	ns	-	-0.12	ns	-0.06	ns	-0.05	-0.17	-0.03	0.11	0.07	-0.13	0.02
Quantifiers	-	-0.09	-	0.24	-	-0.02	-	0.03	-	0.05	-	ns	-	0.05
Numbers	-0.15	-0.13	-	0.05	-0.12	-0.06	0.11	0.02	ns	0.02	ns	ns	-0.08	0.06
Swear words	-0.22	-0.21	-	-0.17	ns	ns	-0.21	-0.15	-0.14	-0.09	0.11	0.06	ns	ns
Social processes	-	0.08	-0.13	0.21	0.15	0.04	0.13	0.02	ns	ns	ns	ns	-0.14	ns
Family	0.12	0.22	-	0.28	0.09	0.03	0.19	0.03	ns	0.03	ns	ns	-0.17	-0.12
Friends	0.09	0.08	-	0.26	0.15	0.05	0.11	0.04	ns	0.02	-0.08	ns	ns	-0.04
Humans	ns	0.04	-	0.06	0.13	0.06	ns	-0.05	-0.12	ns	ns	ns	-0.09	ns
Affective processes	0.11	0.11	-	-0.05	0.09	0.07	ns	0.02	ns	ns	ns	ns	-0.12	-0.04
Positive emotion	ns	0.21	0.12	0.14	0.1	0.13	0.18	0.13	ns	0.1	ns	-0.08	-0.15	-0.07
Negative emotion	0.1	-0.12	-0.05	-0.31	ns	-0.07	-0.15	-0.17	-0.18	-0.13	0.16	0.15	ns	0.03
Anxiety	0.16	0.08	-	-0.13	ns	-0.04	ns	-0.02	ns	-0.02	0.17	0.06	ns	0.07
Anger	ns	-0.22	-	-0.25	ns	-0.05	-0.23	-0.19	-0.19	-0.12	0.13	0.11	ns	0.02
Sadness	0.1	0.08	-	-0.15	ns	-0.04	ns	-0.02	-0.11	-0.04	0.1	0.09	ns	ns

网络行为数据心理识别的基本思路



什么是Likes

people would typically assume to be private. The study is based on Facebook Likes, a mechanism used by Facebook users to express their positive association with (or "Like") online content, such as photos, friends' status updates, Facebook pages of products, sports, musicians, books, restaurants, or popular Web sites. Likes represent a very generic class of digital records, similar to Web search queries, Web browsing histories, and credit card purchases. For example, observing users' Likes related to music provides similar information to observing records of songs listened to online, songs and artists searched for using a Web search engine, or subscriptions to related Twitter channels. In contrast to these other sources of information, Facebook Likes are unusual in that they are currently publicly available by default. However, those other digital records are still available to numerous parties (e.g., governments, developers of Web browsers, search engines, or Facebook applications), and, hence, similar predictions are unlikely to be limited to the Facebook environment.



如何获取数据

Likes – APP MyPersonality

Psychological features – Questionnaires

Other characteristics – Facebook profiles

such a predictive analysis can be, including "sexual orientation," "ethnic origin," "political views," "religion telligence," "satisfaction with life" (SWL), hol," "drugs," "cigarettes"), "whether an stayed together until the individual was 21 mographic attributes such as "age," "gende tus," and "size and density of the friendship Model (9) personality scores (n = 54,373) w the International Personality Item Pool (IPI 20 items (25). Intelligence (n = 1,350) Raven's Standard Progressive Matrices (S (n = 2,340) was measured using the SWL 52,700; average, μ = 25.6; SD = 10), gend female), relationship status ("single"/"in rela 49% single), political views ("Liberal"/"Con

65% Liberal), religion ("Muslim"/"Christian"; n = 18,833; 90% Christian), and the Facebook social network information [n = 17,601; median size, $\tilde{X}$ = 204; interquartile range (IQR), 206; median density, $\tilde{X}$ = 0.03; IQR, 0.03] were obtained from users' Facebook profiles. Users' consumption of alcohol (n = 1,196; 50% drink), drugs (n = 856; 21% take drugs), and cigarettes (n = 1211; 30% smoke) and whether a user's parents stayed together until the user was 21 y old (n = 766; 56% stayed together) were recorded using online surveys. Visual inspection of profile pictures was used to assign ethnic origin to a randomly selected subsample of users (n = 7,000; 73% Caucasian; 14% African American; 13% others). Sexual orientation was assigned using the Facebook profile "Interested in" field; users interested only in others of the same sex were labeled as homosexual (4.3% males; 2.4% females), whereas those interested in users of the opposite gender were labeled as heterosexual.

标注数据的获取

- 人格特征(大五人格模型，通过IPIP问卷获得);
- 人种 (白种人/黑种人，通过个人资料的照片获得);
- 智商 (通过SPM问卷获得)
- 生活满意度(通过SWL问卷获得);
- 双亲在个体21岁之前是否离婚 (通过在线调查获得);
- 性取向(通过用户关注的人的性别推测)
- 其他(通过Facebook个人资料获得) : 年龄; 性别; 恋爱关系; 朋友圈规模和热度; 政治观点; 宗教信仰; 不良嗜好(吸毒，抽烟，酗酒);

如何计算个人特征

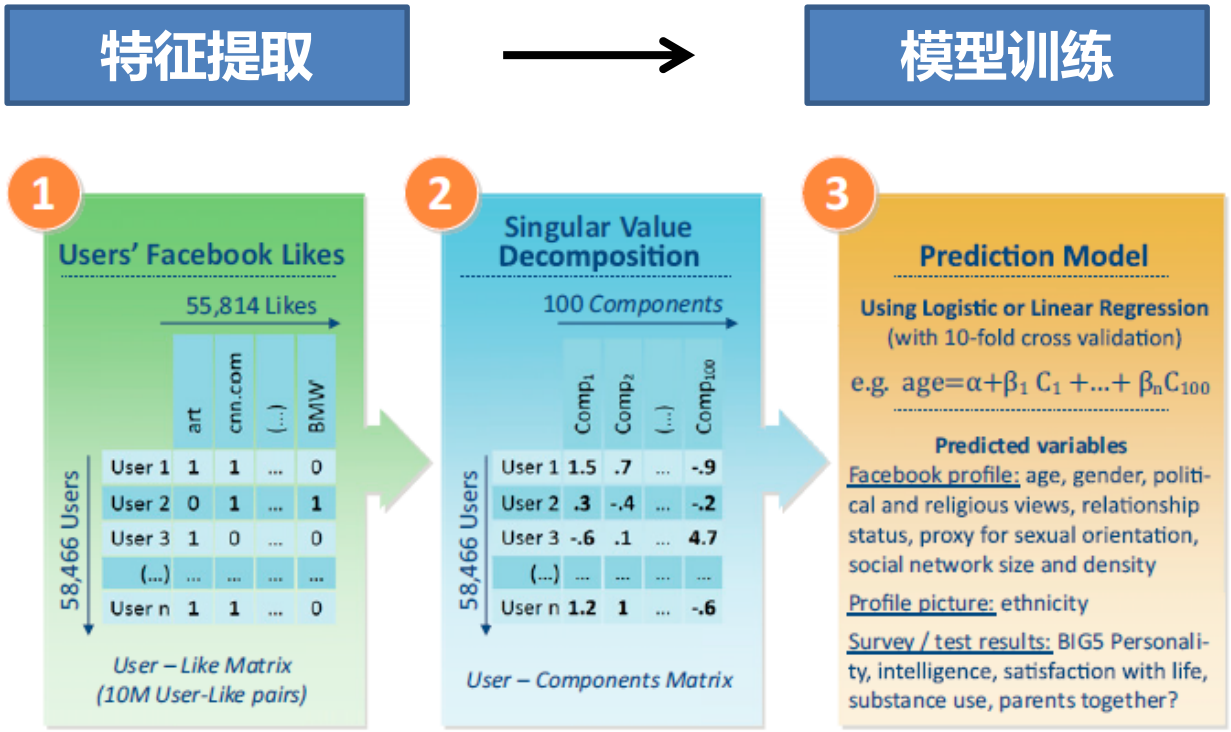


Fig. 1. The study is based on a sample of 58,466 volunteers from the United States, obtained through the myPersonality Facebook application (www.mypersonality.org/wiki), which included their Facebook profile information, a list of their Likes (n = 170 Likes per person on average), psychometric test scores, and survey information. Users and their Likes were represented as a sparse user–Like matrix, the entries of which were set to 1 if there existed an association between a user and a Like and 0 otherwise. The dimensionality of the user–Like matrix was reduced using singular-value decomposition (SVD) (24). Numeric variables such as age or intelligence were predicted using a linear regression model, whereas dichotomous variables such as gender or sexual orientation were predicted using logistic regression. In both cases, we applied 10-fold cross-validation and used the k = 100 top SVD components. For sexual orientation, parents' relationship status, and drug consumption only k = 30 top SVD components were used because of the smaller number of users for which this information was available.

User-Like 矩阵的构建

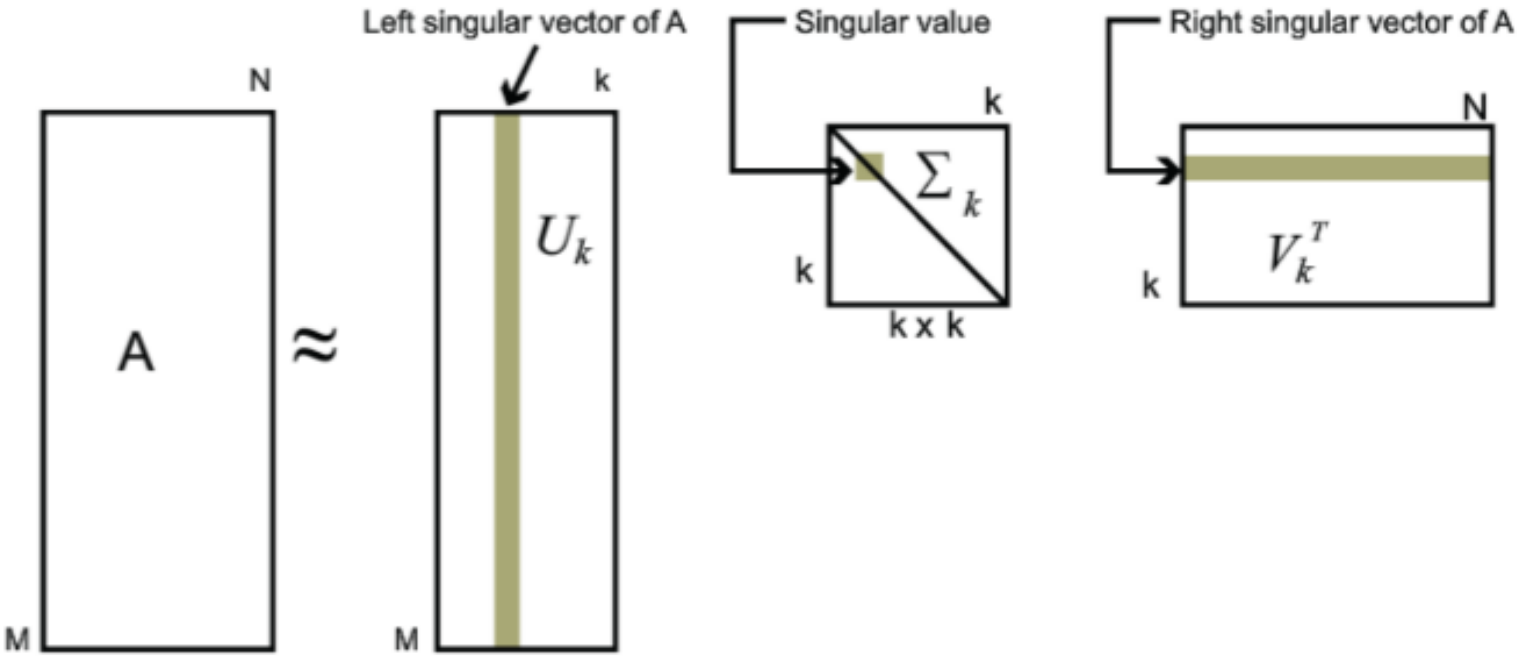


- Facebook的点赞机制将用户与各个兴趣标签联系在一起，比如“艺术”，“cnn网”。
- 研究团队整理出约900万个标签，筛除只有不到20个人点过赞的标签后，共55814个兴趣标签，58466个用户。
- 如果用户X 给兴趣对象Y点赞，那么矩阵的(X,Y) 项为1，否则为0。

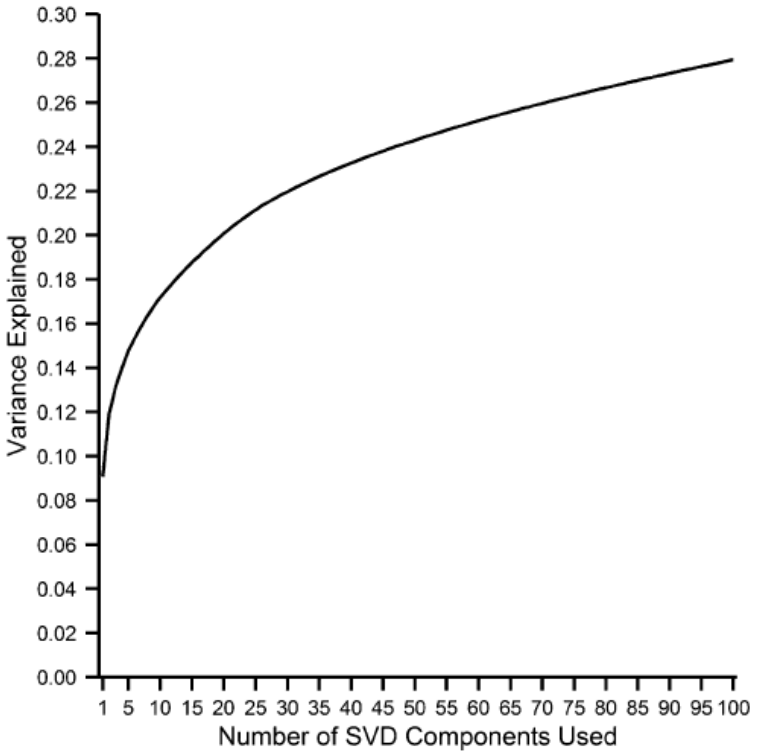
特征降维

- SVD： 对矩阵A做奇异值分解，取前k个奇异值，原矩阵就可以近似表示为三个小矩阵的乘积，从N维降到k维。

$$A_{m\times n} = U_{m\times m}\Sigma_{m\times n}V^T_{n\times n} \approx U_{m\times k}\Sigma_{k\times k}V^T_{k\times n}$$



特征降维



- 为了确定SVD降维中的最优k值，研究团队绘制了预测准确度关于维度数的函数，如右图所示。

- 最后，他们选定 k =100，足以表示28%的总方差。而在预测性取向，父母关系，药物滥用时，由于有效数据较少，选定k=30。

模型训练-算法

- 对于数值型数据的预测，使用线性回归模型:

$$\hat{y}_i = w^T x_i \qquad J = \frac{1}{2m}\sum_{i=1}^{m}(\hat{y}_i - y_i)^2$$

- 对于二分型数据的预测，使用Logistic回归模型：

$$\hat{y}_i = \frac{1}{1+e^{-w^T x_i}} \qquad J = -\frac{1}{m}\sum_{i=1}^{m}(y_i \log \hat{y}_i + (1-y_i)(1-\log \hat{y}_i))$$

模型训练-交叉验证

- 为了避免过拟合，回归模型可使用10折交叉验证。数据被随机分为10等份，其中9份用于训练集，1份用于测试集。循环10次直到每一份都曾经作为测试集。



结果

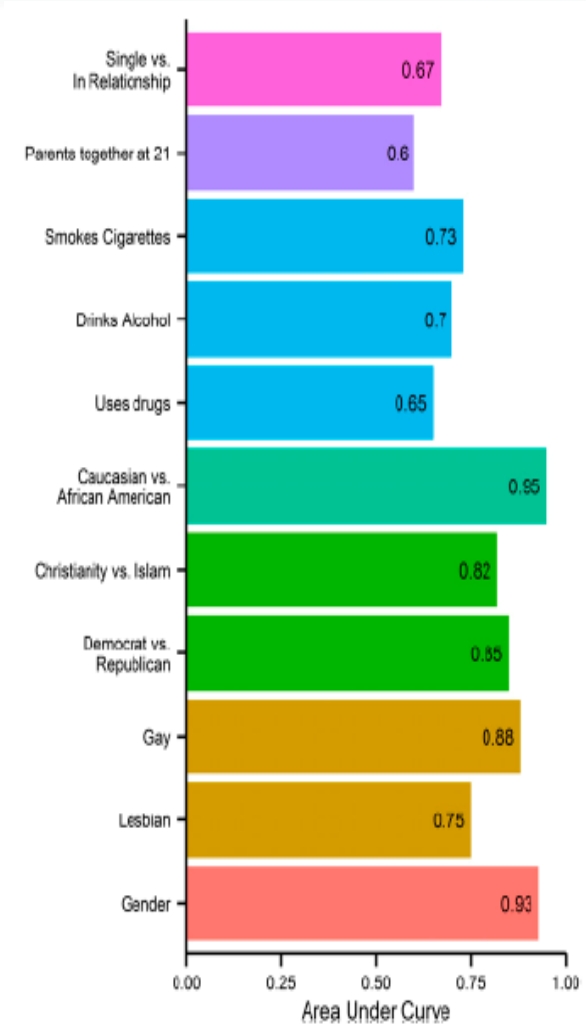
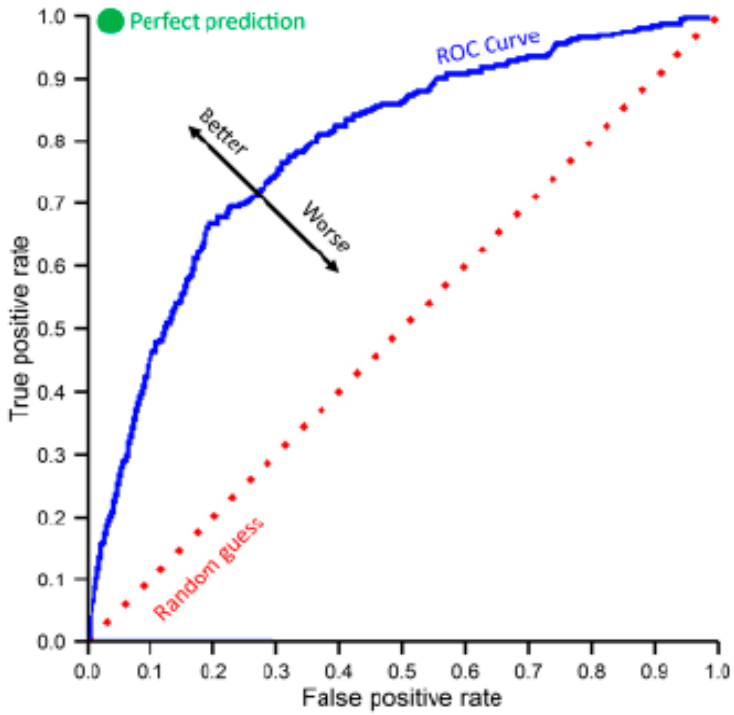


Fig. 2. Prediction accuracy of classification for dichotomous/dichotomized attributes expressed by the AUC.

- 二分型数据的预测准确度用AUC表示。
- AUC 是ROC曲线下的面积，可以解释为正确区分两个随机对象的概率。



结果

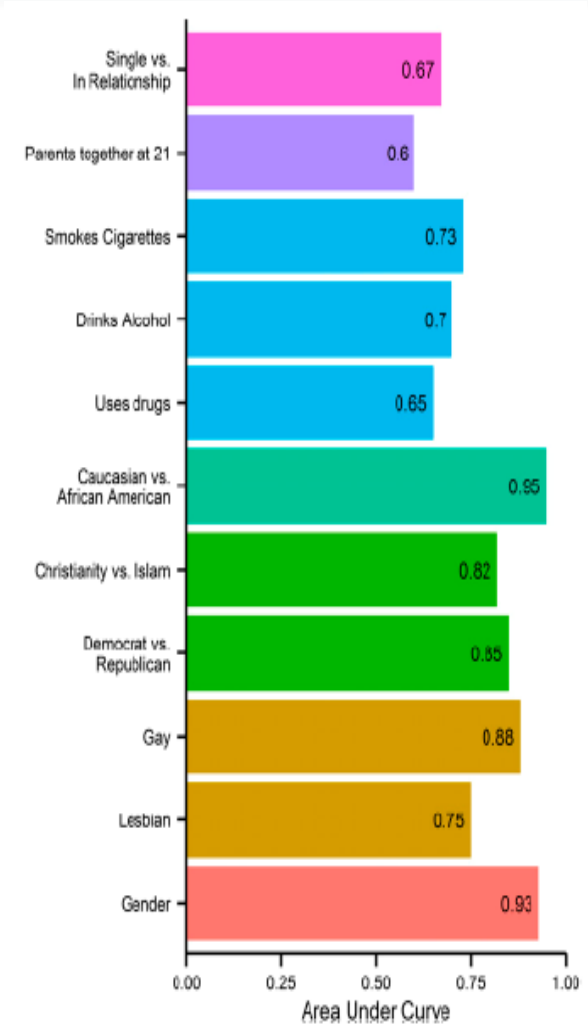


Fig. 2. Prediction accuracy of classification for dichotomous/dichotomized attributes expressed by the AUC.

- 预测人种的准确度达到了最高的95%，预测性别的准确度达到了93%。这暗示着，这些群体之间的在线行为可能有很大区别。
- 宗教信仰，政治观点，性取向的预测都达到了不错的效果。但在恋爱关系上的准确度比较低，这可能是由于恋爱关系的不稳定性。
- 预测父母是否在个体21岁前离婚的准确度最低。

结果

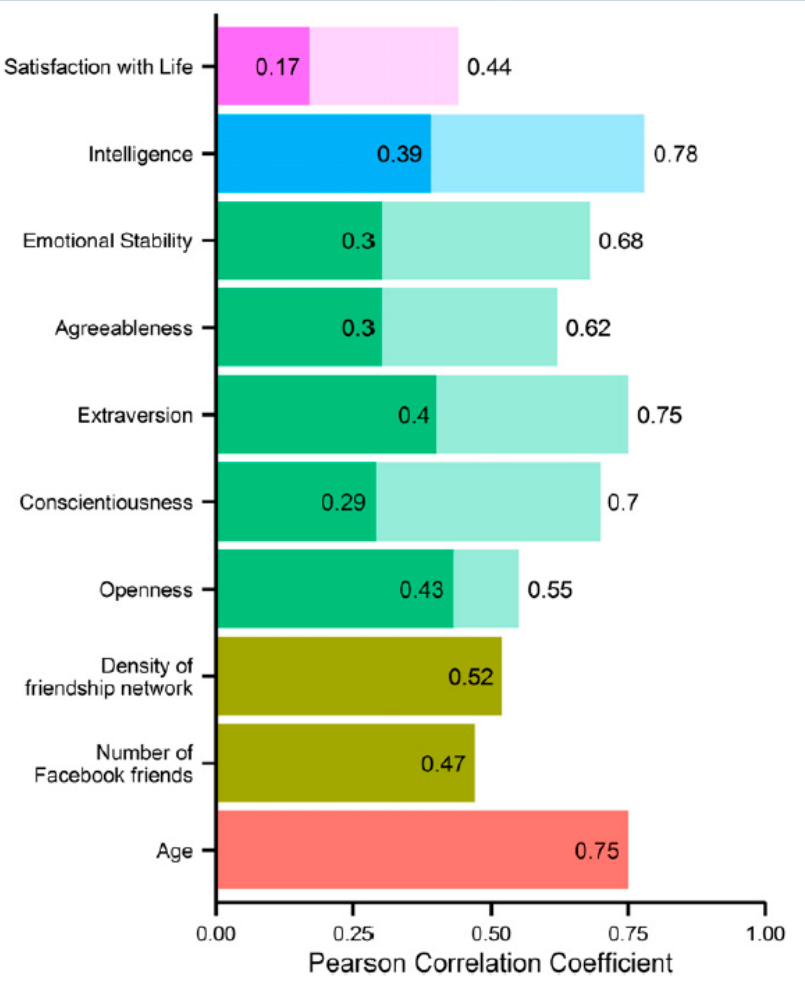


Fig. 3. Prediction accuracy of regression for numeric attributes and traits expressed by the Pearson correlation coefficient between predicted and actual attribute values; all correlations are significant at the $P < 0.001$ level. The transparent bars indicate the questionnaire's baseline accuracy, expressed in terms of test–retest reliability.

- 数值型数据的准确度用皮尔逊相关系数表示。

- 皮尔逊相关系数用于衡量变量之间的线性相关的程度。

$$\rho_{X,Y} = \frac{\operatorname{cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{E[(X-\mu_X)(Y-\mu_Y)]}{\sigma_X \sigma_Y},$$

结果

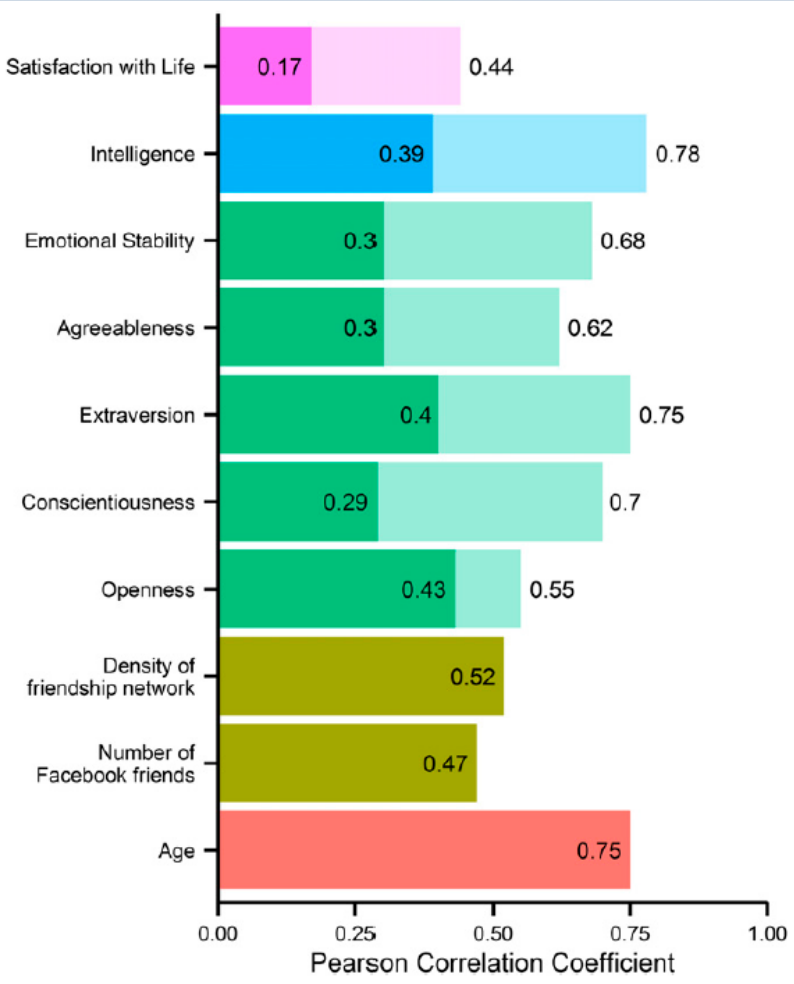


Fig. 3. Prediction accuracy of regression for numeric attributes and traits expressed by the Pearson correlation coefficient between predicted and actual attribute values; all correlations are significant at the $P < 0.001$ level. The transparent bars indicate the questionnaire's baseline accuracy, expressed in terms of test–retest reliability.

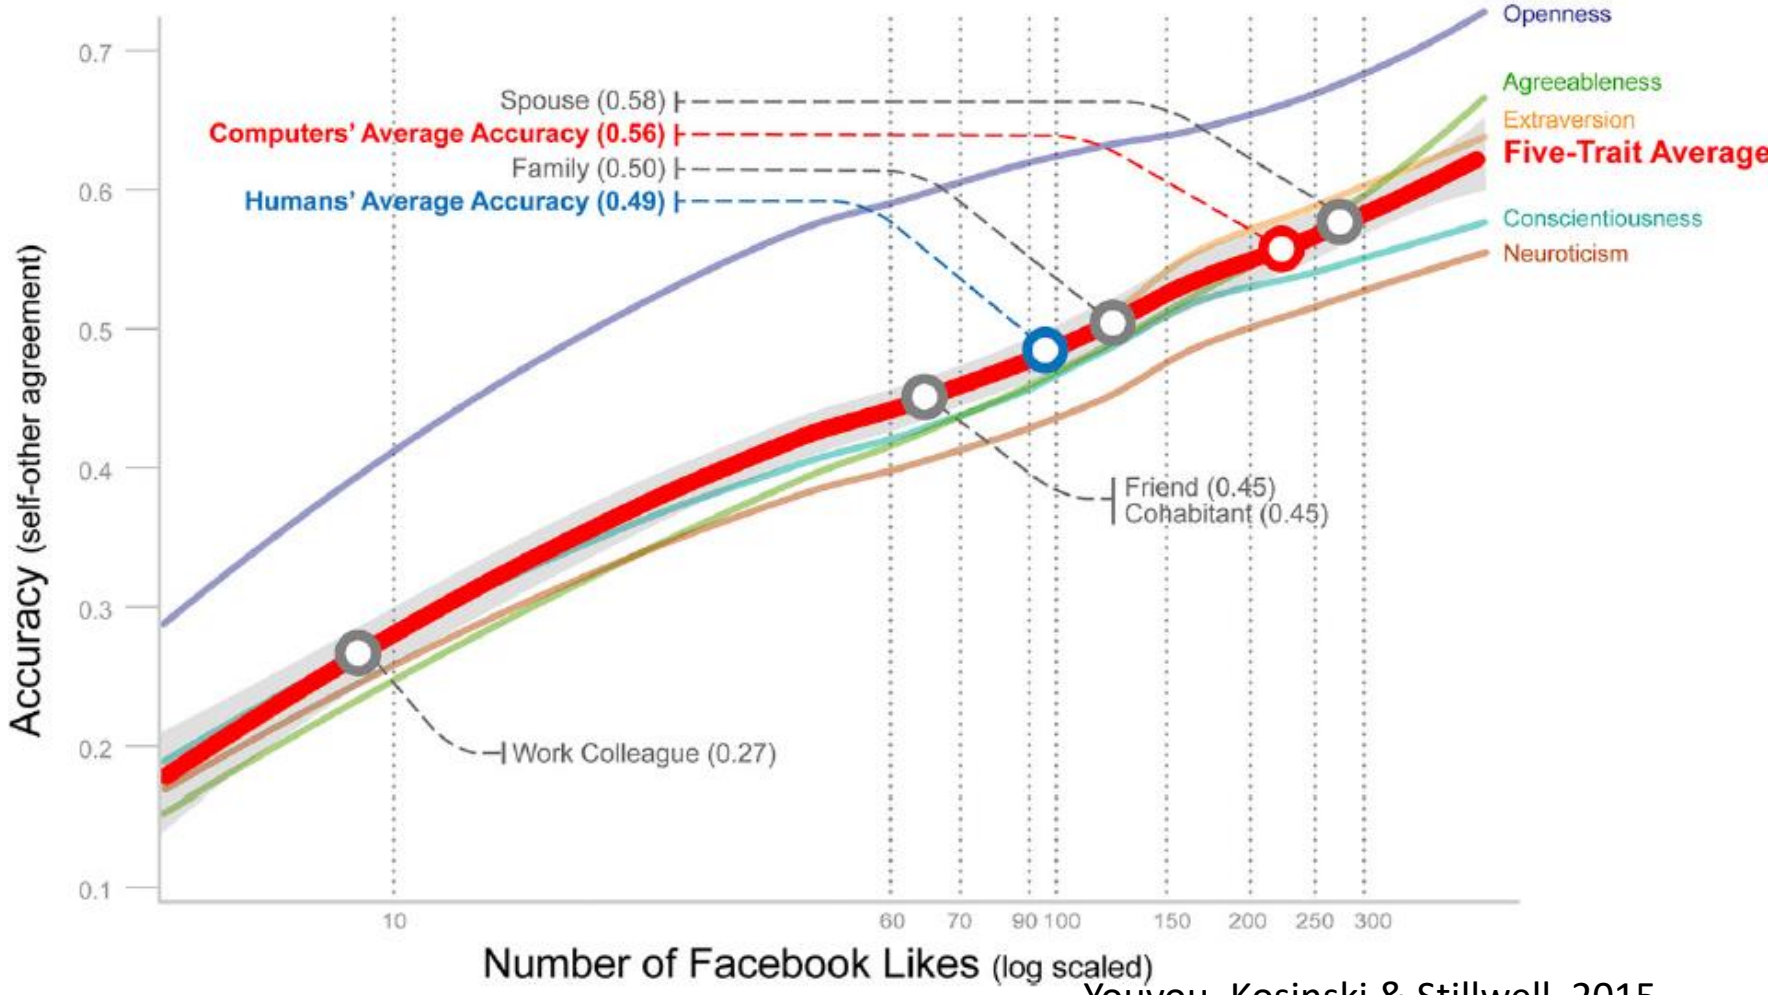
- 在开放性的预测上，预测值和真实值之间的相关系数达到了0.43，与重测信度（r=0.55）非常接近。
- 这意味着，在测量开放性时，观察用户的点赞行为和使用问卷获得的结果差不多。
- 在主观幸福感上的预测效果相对最低（r=0.17），这可能是由于主观幸福感受到短期的心理波动影响，而该模型更适合预测长期稳定的特征。

计算机识别与个体评价的效果比较

- 主要比较计算机模型和人类在预测大五人格的自我-他人一致性上的结果。
- 计算机模型使用LASSO模型。LASSO与线性回归模型相比，在代价函数上加入了系数的绝对值之和，使得模型压缩了一些回归系数，达到特征筛选的效果。

$$Y = X\beta + \varepsilon, \qquad \hat{\beta}_{Lasso} = \arg\min_{\beta \in R^d} \left(\left\| Y - X\beta \right\|^2 + \lambda \sum_{j=1}^{d} \left| \beta_j \right| \right),$$

效果如何



Youyou, Kosinski & Stillwell, 2015

生态化识别

在网络空间中获取生活中的真实行为记录，利用机器学习训练得到的心理特征预测模型，实现**生态化识别**（Ecological Recognition, ER），大大拓展心理与行为研究的范畴。



Mingming Liu, Jia Xue, Nan Zhao*, Xuefei Wang, Dongdong Jiao, Tingshao Zhu*. (2018). Using Social Media to Explore the Consequences of Domestic Violence on Mental Health. Journal of Interpersonal Violence. Feb. 2018, https://doi.org/10.1177/0886260518757756

大数据心理建模应用

网络行为分析

- 行为特征提取
- 应用举例

线下行为分析

- 步态
- 面部
- 语音

大数据心理建模应用

网络行为分析

- 行为特征提取
- 应用举例

线下行为分析

- 步态
- 面部
- 语音

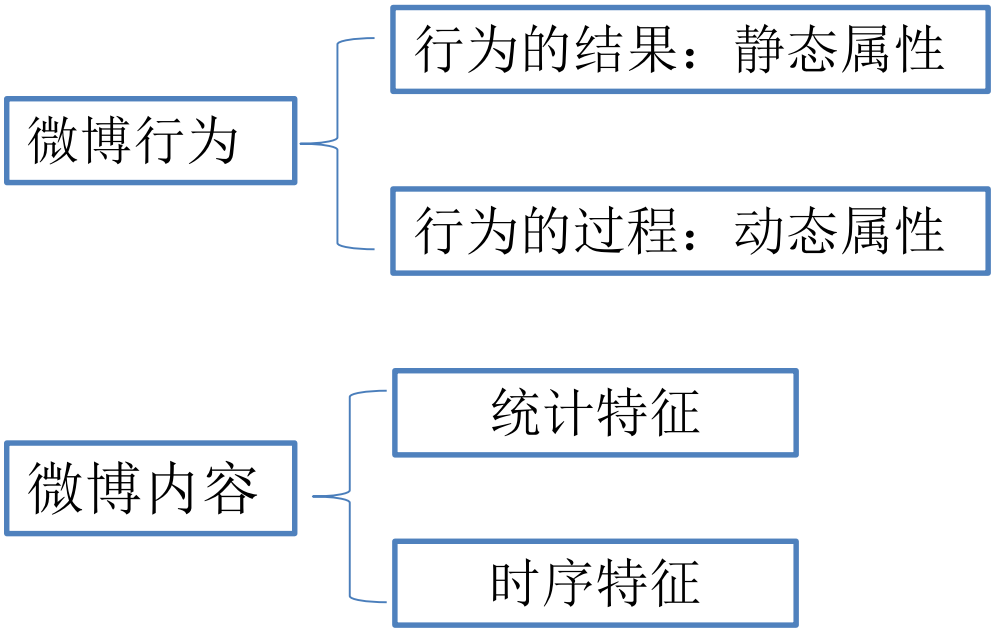
研究背景

- 特征提取是机器学习的传统难题，提取出的特征泛化能力的好坏直接影响模型的训练结果，根据具体的应用领域对特征进行合理有效的设计是整个机器学习过程构建的基础。

特征提取

特征的选取会影响模型的效果，需要满足两点：

与预测目标存在关联性；能够表征样本区别于其他样本的特点



将微博行为和内容以数字形式量化的过程

从微博数据中提取行为特征

静态行为特征，包括**用户微博属性**（如性别、地区等）、**用户自我展示行为**（如自我描述长度，昵称长度等），**用户的自我保护性行为**（如是否允许所有人给我发私信等），**用户的社交行为**（如微博数，关注数等）。

动态行为特征，是指用户的行为随时间变化而快速变化，包括：**发送微博**（如微博出现正性表情，微博发送途径等）、**@行为**（@好友个数等）、**使用应用行为**（使用娱乐应用、使用信息应用等）和**可记录的浏览行为**（看娱乐应用、看媒体微博等）几类。

针对动态行为特征按不同时间粒度划分可获取**时序行为特征**

微博用户统计性行为特征（静态行为特征）

我们将静态行为划分四大类，总共提取了45个静态行为特征，其中4个用户微博属性、18个用户自我展示行为，3个用户的自我保护性行为，20个用户的社交行为

- 用户的微博属性：指用户随时间变化不易发生改变的微博属性，这些属性包括微博用户的固有微博属性和被微博记录的人口统计特性。
  - 性别
  - 所在地城市编号
  - 所在地省编号
  - 注册时间长度

微博用户统计性行为特征（静态行为特征）

- 用户的自我展示行为：用户对自己微博账号一些可以让粉丝察觉到的设置或者展示行为，这类行为随时间的变化会有变化，但是会在一定的时间段内保持相对的稳定，代表用户一定时间段内的行为偏好。

- 是否是默认头像
- 自我描述的长度
- 自我描述是否有我
- 个性域名的长度
- 个性域名中是否有数字
- 是否认证

- 认证类型
- 认证原因的长度
- 屏幕名字的长度
- 屏幕名字中文占的比重
- 是否有新浪博客
- 用户新浪博客域名和新浪域名是否一致

- 热度0-100标签数
- 热度100-10000标签数
- 热度>10000标签数
- 热度0-100话题数
- 热度100-10000话题数
- 热度>10000话题数

微博用户统计性行为特征（静态行为特征）

- 用户的自我保护性行为（用户的安全信息设置）：这类行为会随着时间变化而变化，但是会在一段时间内保持不变，有更强的目的性。

  - 是否允许所有人给我发私信
  - 是否允许所有人对我的微博进行评论
  - 是否允许带有地理信息

微博用户统计性行为特征（静态行为特征）

- 用户的社交行为：利用API抓取的微博数据，难以捕捉其随着时间的变化的社交行为。

- 用户所有微博中原创微博占的比例
- 收藏数
- 微博数
- 关注数
- 粉丝数目

- 互粉人数
- 互粉数占总粉丝人数的比例
- 互相粉丝数占所有关注的比例
- 相互用户关注总类别数
- 相互关注人群第1多的用户类别
- 相互关注人群第2多的用户类别
- 相互关注人群第3多的用户类别
- 微博转发用户总类别数

- 微博转发第1多的用户类别
- 微博转发第2多的用户类别
- 微博转发第3多的用户类别
- 用户关注的用户总类别数
- 关注人群第1多的用户类别
- 关注人群第2多的用户类别
- 关注人群第3多的用户类别

动态行为的时序特征（微博行为的时序特征）

- 细粒度动态行为的时序特征设计（按天）
- 基于信息论的动态行为的时序特征设计（按周）

细粒度动态行为的时序特征设计（按天）

确定动态特征列表



将动态特征转化为二维矩阵



提取时间序列



时序特性统计量计算

确定动态行为列表

- 结合用户使用微博的习惯特点，我们总结了微博用户常见的40条动态行为（微博行为），包括发送微博（12个特征）、@行为（3个特征）、使用应用行为（6个特征）和可记录的浏览行为特征（19个特征）

动态行为列表

发送微博

- 发送微博
- 发送微博出现表情
- 发送微博出现正向表情
- 发送微博出现负向表情
- 使用台式机发微博
- 使用其他途径发送微博

- 发送原创微博长度
- 发送原创微博去冗余长度
- 发送原创热门微博
- 发送原创微博出现表情
- 发送原创微博出现正向表情
- 发送原创微博出现负向表情

动态行为列表

@行为:

- @好友
- 原创微博@个数
- 原创微博@好友

使用应用:

- 使用应用
- 使用信息应用
- 使用交易应用
- 使用社交应用
- 使用娱乐应用
- 使用其他应用

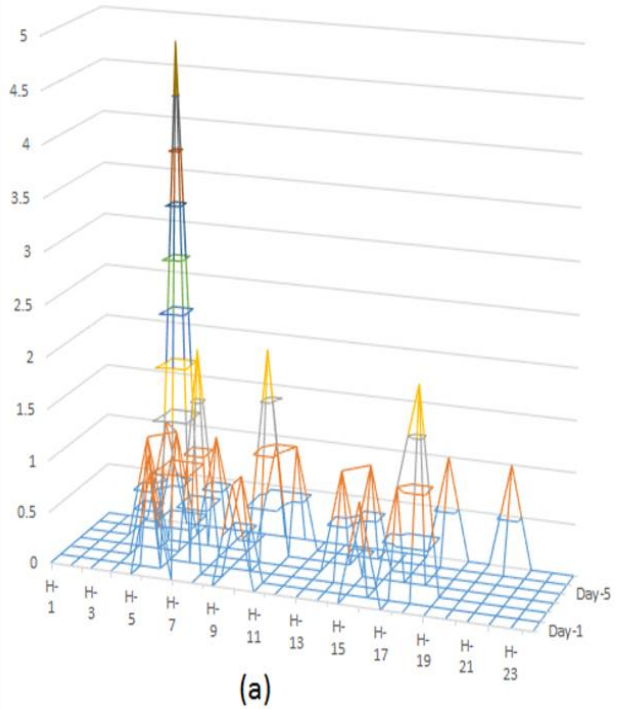
动态行为列表

可记录的浏览行为

- 看好友微博
- 看应用消息
- 看信息应用
- 看交易应用
- 看社交应用
- 看娱乐应用
- 看其他应用
- 看个人认证的微博
- 看政府的微博
- 看企业的微博
- 看媒体微博
- 看校园官方微博
- 看网站官方微博
- 看应用官方微博
- 看机构团体微博
- 看微博女郎微博
- 看微博初级大人微博
- 看微博中高级微博
- 看热门微博

建立特征矩阵

- 将6点作为一天的开始时间，小时数即表示一天中从6点到行为发生时间点的小时间隔数
- 天代表在观察周期内，行为发生的日期到观察周期开始日期之间间隔的天数。
- 对每一个动态行为的时间序列，可以将其转换成一个24*n的二维矩阵。
- 矩阵中第i行第j列的元素值代表在观察周期第j天第i个小时段内，用户发生该行为的个数。



(a)

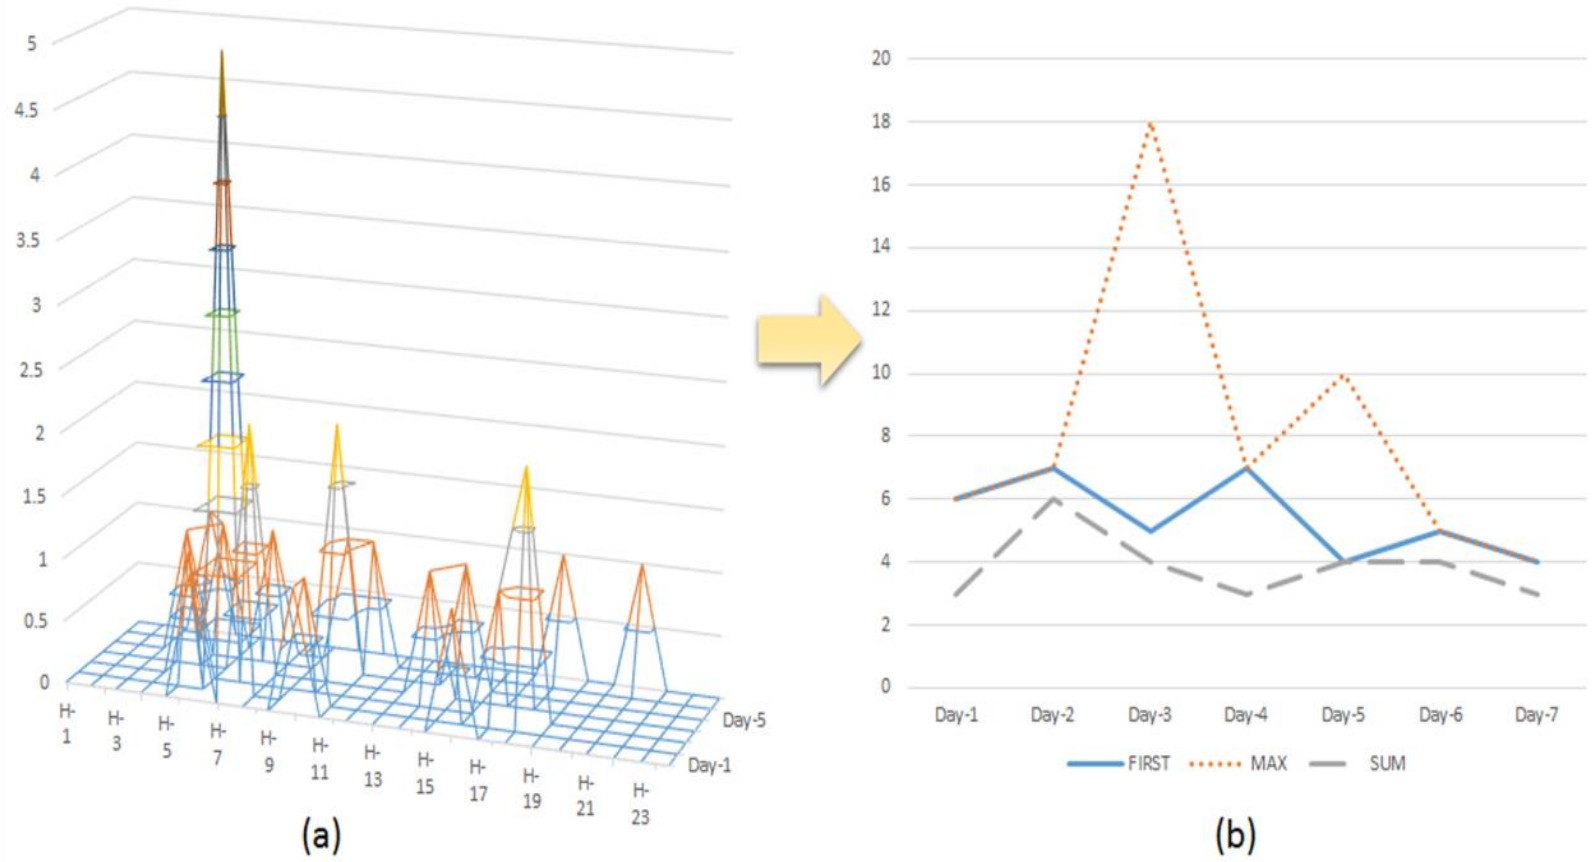
从矩阵中提取时间序列

- 以用户发送微博这个动态行为为例
  - 依次提取矩阵中每一列的第一个非零元素的行号作为一个时间序列。对微博用户发送微博这个动态行为而言，即表示微博用户每天发送第一条微博所在的时间段的时间序列。
  - 依次提取矩阵中每一列的最大元素的行号作为一个时间序列。对微博用户发送微博这个动态行为而言，即表示微博用户每天发送微博最频繁的时间段的时间序列。

从矩阵中提取时间序列

- 依次对矩阵按列求和作为一个时间序列。对微博用户发送微博这个动态行为而言，即表示用户每天发送微博总数的时间序列。
- 依次对矩阵按行求和作为组一个时间序列。对微博用户发送微博这个动态行为而言，即表示用户在观察周期不同时间段发送微博总数的时间序列。
- 将矩阵中所有的列按周一到周日求和作为一个时间序列（1*7的序列）。对微博用户发送微博这个动态行为而言，即表示用户在观察周期中周一到周日发送微博数的时间序列。

从矩阵中提取时间序列


5
4.5
4
3.5
3
2.5
2
1.5
1
0.5
0
H-1
H-3
H-5
H-7
H-9
H-11
H-13
H-15
H-17
H-19
H-21
H-23
Day-5
Day-1
(a)
20
18
16
14
12
10
8
6
4
2
0
Day-1
Day-2
Day-3
Day-4
Day-5
Day-6
Day-7
FIRST
MAX
SUM
(b)

计算时间序列的统计量

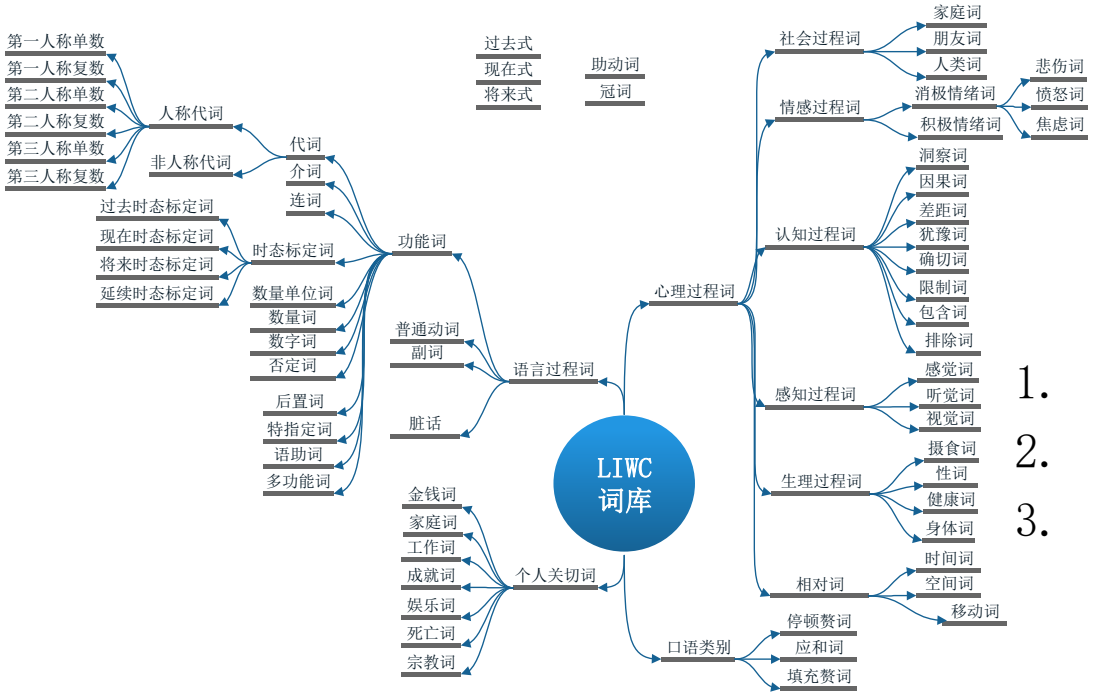
- 通过计算时间序列的统计量，完成动态行为时序特征的数值化。我们计算了4个时间序列的统计量来刻画动态行为的时序特征：均值、标准差、求和以及加权求和（比如所用户发送微博所在时间段的加权求和）。
- 我们从总结的40个常见动态行为中提取了200个时间序列，进而根据200个时间序列计算得到了800个的统计量值。
- 通过此特征设计方法，我们对单个动态行为的时序特征尽可能多的挖掘，使该特征设计方法对动态特征的时序描述丰富，但是，由于以天和小时为计量单位，细粒度动态特征的时序特征设计方法计算出来的统计量特征所表现出来的特征粒度相对较小，导致模型训练特征较多。

总结

- 细粒度动态行为的时序特征设计方法提取动态行为特征的时间粒度以天为单位，重点在于对单个动态行为的深度挖掘
- 细粒度动态行为的时序特征设计方法提取了40个动态行为，从生成的40个特征矩阵中提取了200个动态行为的时间序列，对每个时间序列提取四个统计量，最后转化为800动态行为的时序特征，加上45个静态行为，组成一个包含845个行为的行为集合；

从微博数据中提取内容特征

中文微博心理分析词库（SCLIWC）：参考英文版LIWC和繁体CLIWC，共包含23000+个常用词语，覆盖了微博中的高频词汇，根据词语的情绪表达程度及类别不同分为76+11类



1. 四位心理学博士研究生标注。
2. 四位主试对结果进行评议，消除分歧。
3. 另外三名进行信效度检验。

从微博数据中提取内容特征

“文心（TextMind）”中文心理分析系统主要由SCLIWC和文心软件程序组成，为用户提供自动分词、语言心理分析功能。

http://ccpl.psych.ac.cn/textmind/

统计文档中所有词所属各类别的个数，例如：

今天很高兴 ⟹ 结果：积极词1个



funct	33.95
pronoun	4.24
ppron	2.40
i	0.37
we	0.00
you	0.18
shehe	1.85
they	0.00
ipron	1.85
verb	10.33
auxverb	3.14
adverb	7.01
preps	4.24
conj	3.87
negate	1.48
quant	3.14
number	1.29
swear	0.00
youpl	0.00
PrepEnd	1.66
SpecArt	0.92
QuanUnit	2.58

大数据心理建模应用

网络行为分析

- 行为特征提取
- 应用举例

线下行为分析

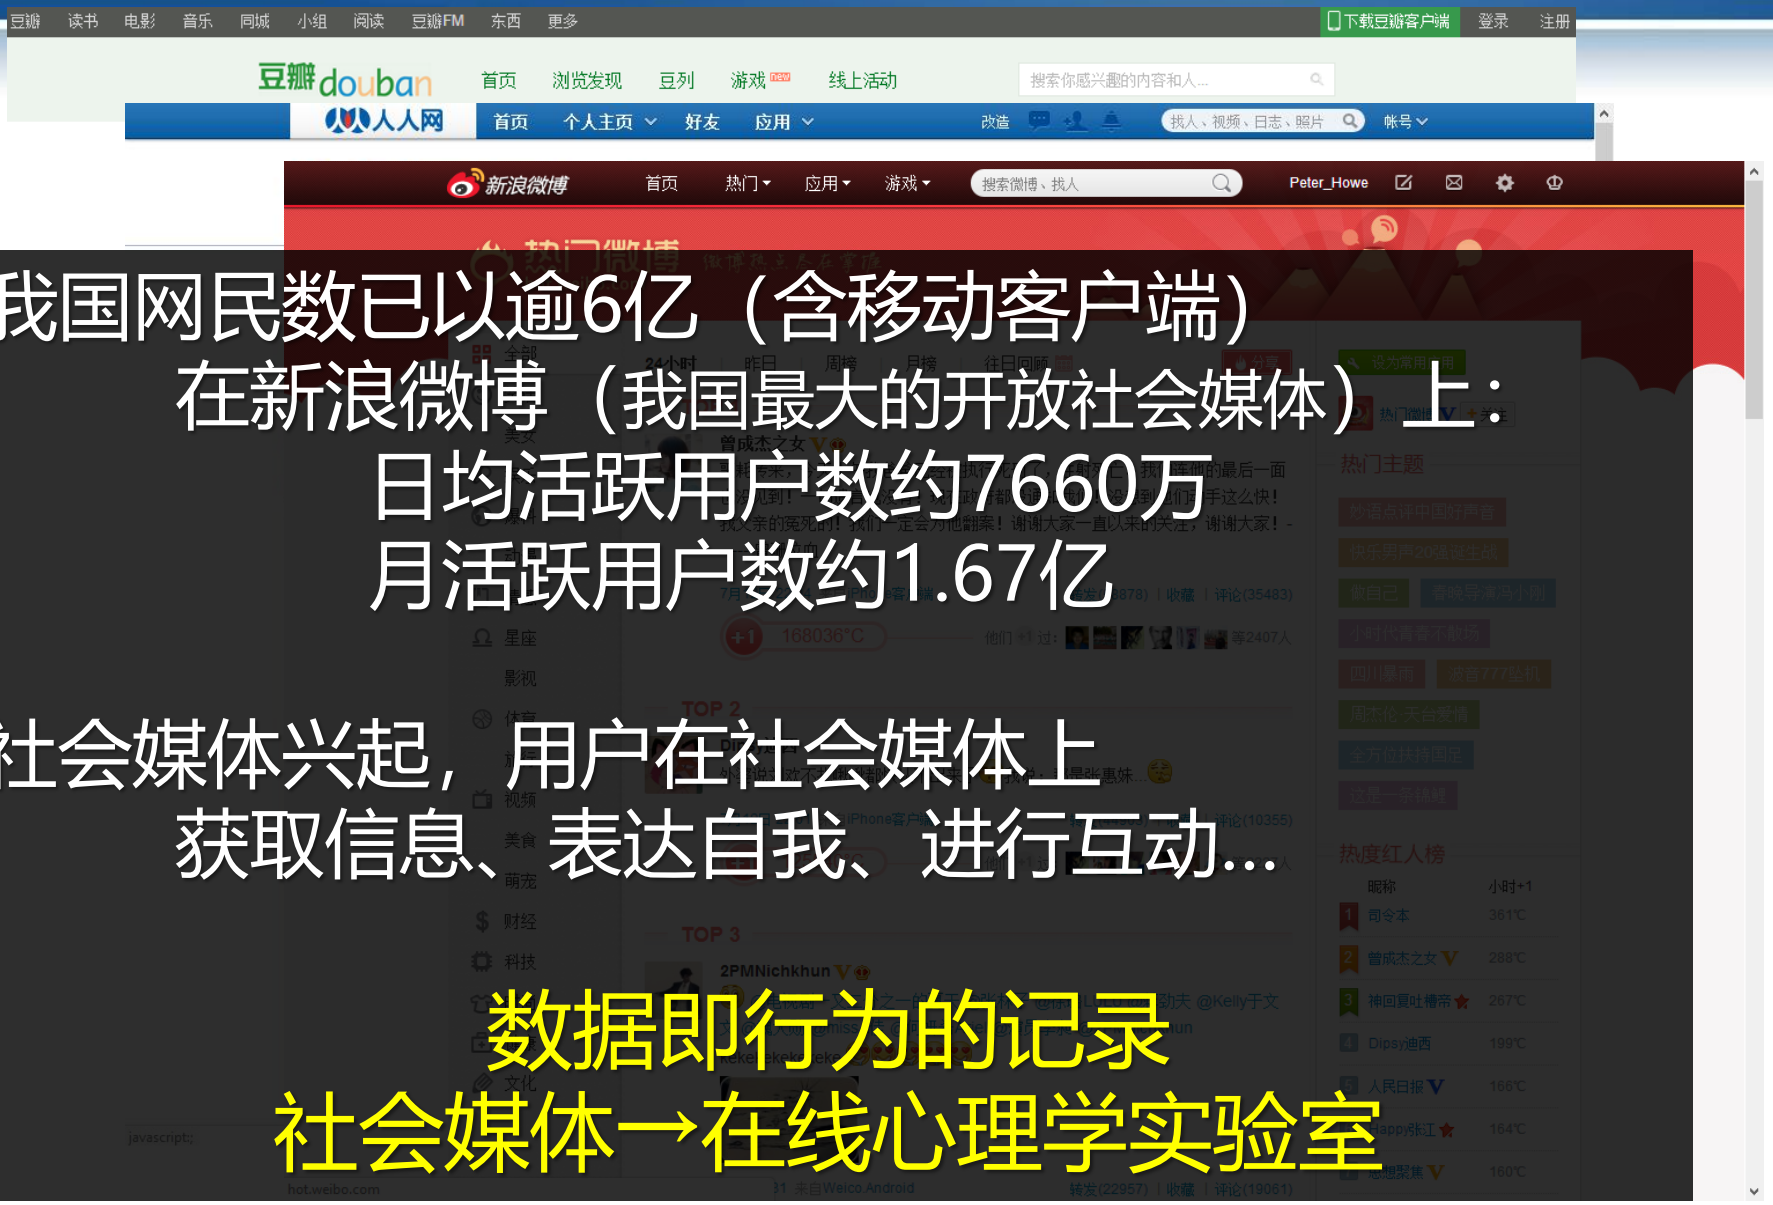
- 步态
- 面部
- 语音

社会需求

e.g.: 你幸福吗?

- 了解民众对生活状况的的主观感受
- 为公共政策制定、政府决策提供支持
  - 民众的心理特质(trait)、状态(status)
- 传统基于自陈的心理测评方式的不足：
  - 受社会赞许性影响
  - 无法及时、大规模地获取用户的心理特征

社会媒体带来的机遇



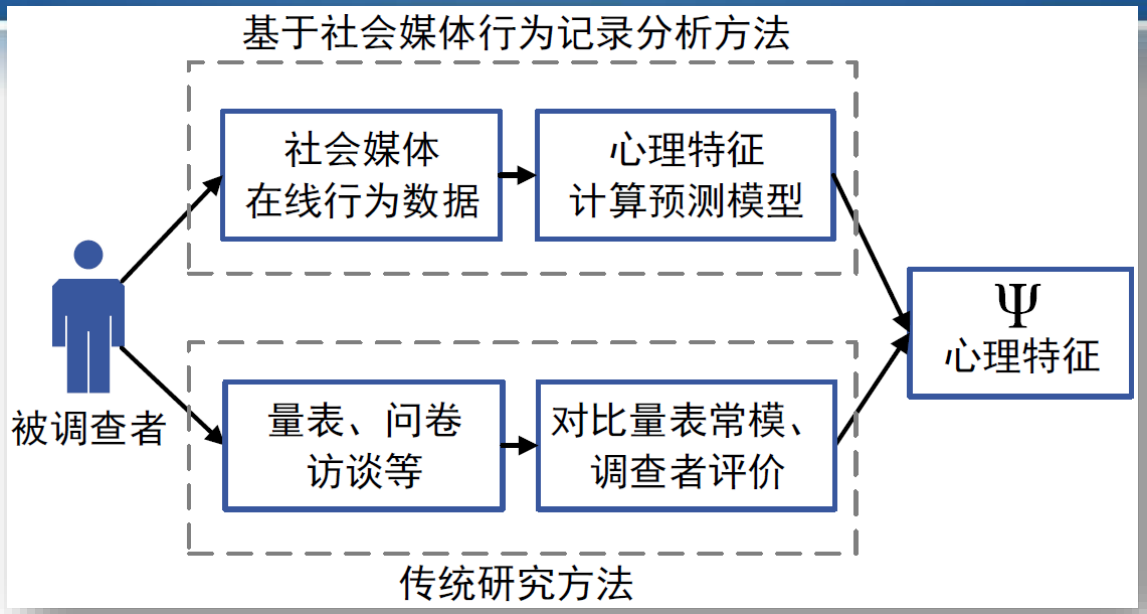
我国网民数已以逾6亿（含移动客户端）
在新浪微博（我国最大的开放社会媒体）上：
日均活跃用户数约7660万
月活跃用户数约1.67亿

社会媒体兴起，用户在社会媒体上
获取信息、表达自我、进行互动…

数据即行为的记录
社会媒体→在线心理学实验室

问题提出 » 研究问题

通过社会媒体来分析预测用户的心理特征



研究目标

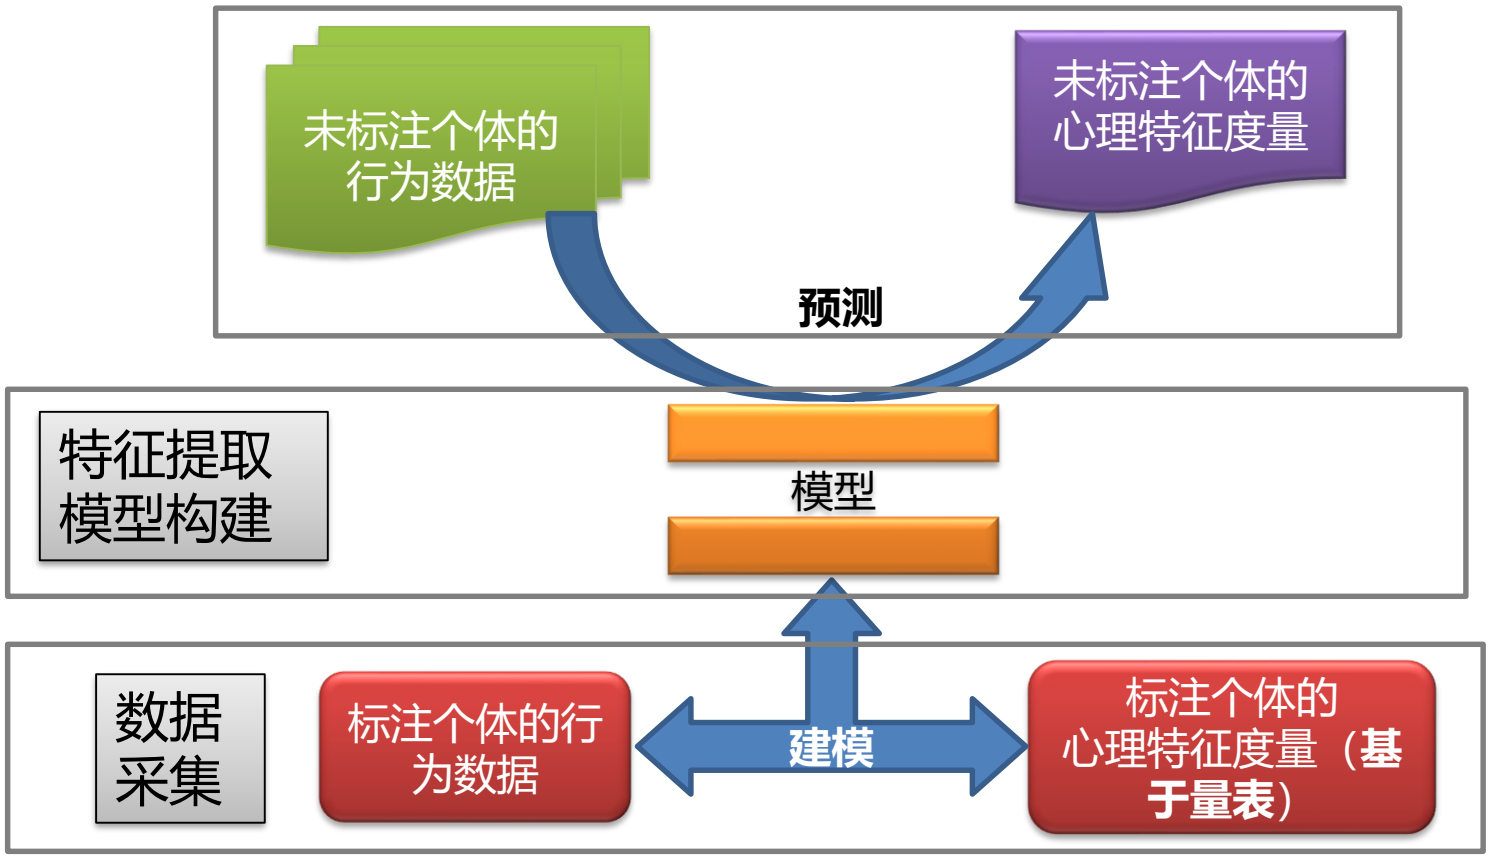
- **基于**心理科学中对特定心理特征（如“幸福感”）的定义
- **在**网络社会媒体（微博）**上**，利用用户行为数据
- **研究**出一种能够**预测**用户心理特征的**方法**
- 要求具有一定的**信度**，能开展**大规模**、**实时**分析

科学问题

- 从社会媒体行为中**提取**用于心理特征预测的有效**指标**
- 利用上述指标，**构建**预测**模型**

整体研究思路

转化为机器学习问题，“学习”行为模式与心理特征间的关系



outline

- 个体心理特征计算
- 社会心态感知
- 突发事件舆情分析

基于微博的人格预测

预实验研究：在较小数据集上利用深度学习模型提取语义特征向量，利用线性回归模型预测人格。

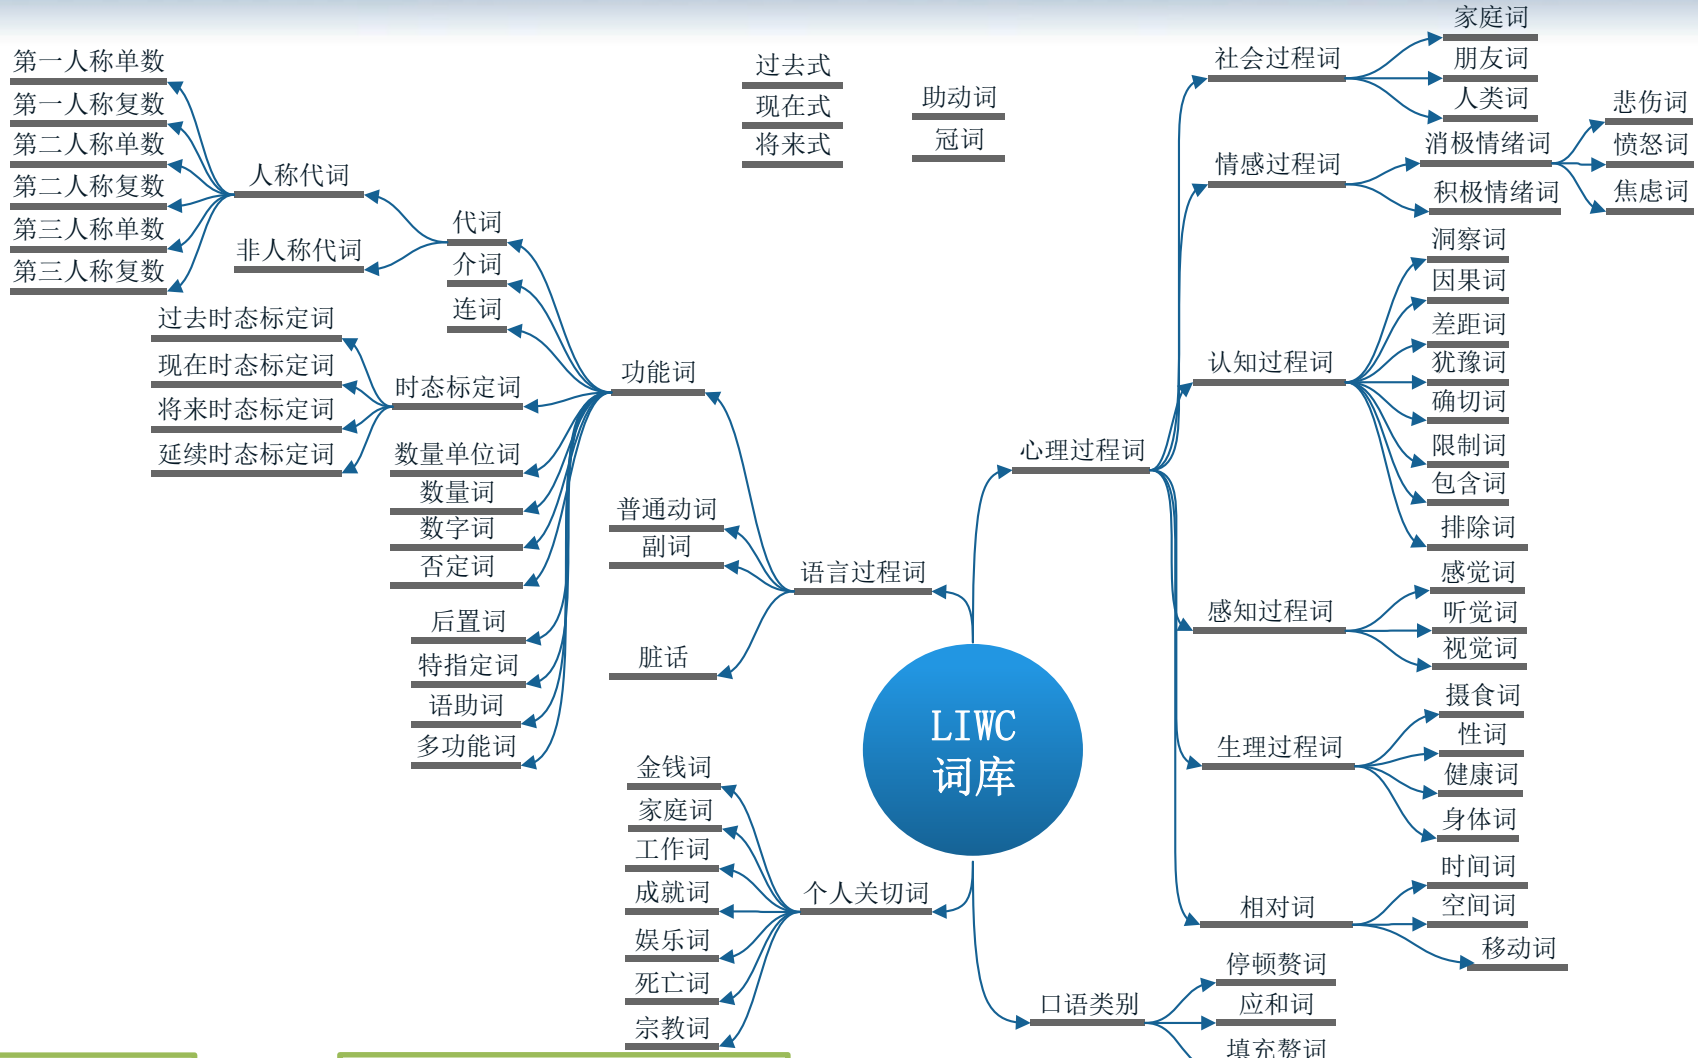
语义信息的获取

根据LIWC词典，计算1706个新浪微博用户在88个维度上的语言使用情况。

针对每个词类，我们以周为时间单位，计算每个用户近三年内(Jun.2011 ~Jun.2014)的微博词语使用情况。因此，对应于每一个词的类别，我们可以得到一个含有156个元素的向量。

为了获得在时间空间的变化，每一个向量，被认为是傅立叶时间序列分析，进行快速傅里叶变换（FFT），我们取前8个振幅最大量表示每类词语的使用特点。最后，将向量串联，获得704长度的语义信息向量。

内容特征 – 词库词频特征



今天很高兴 → 结果：积极词1个

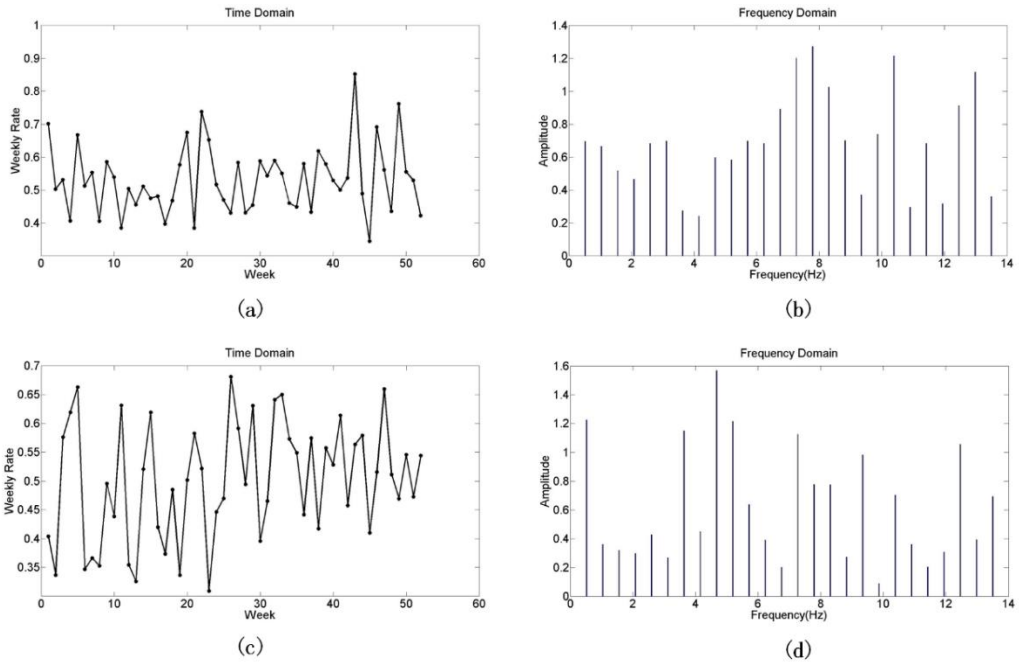
文本特征

微博行为信息的原子级量化方法，考虑微博行为的时序性，对微博行为的动态刻画

微博行为
- 微博操作使用行为
- 微博文本

网络行为特征体系

“文心”/ N-gram 模型



N-gram: 针对文本信息，基于词典的思想和N-gram算法对微博文本进行数字量化。建立对应数据集的特征词典，统计二元词的出现次数占其中各单词出现次数，将文本进行数字量化。

利用FFT提取时间轴上连续信号的频率域信息，从另一角度找到区分性更强且能够动态刻画行为模式的特征表达。

基于微博的人格预测

基于Stacked Autoencoders（SAE）构建面向大五人格预测的特征学习模型

$$y = f_\theta(x) = s(Wx + b)$$

$$x' = g_{\theta'}(y) = s'(W'y + b')$$

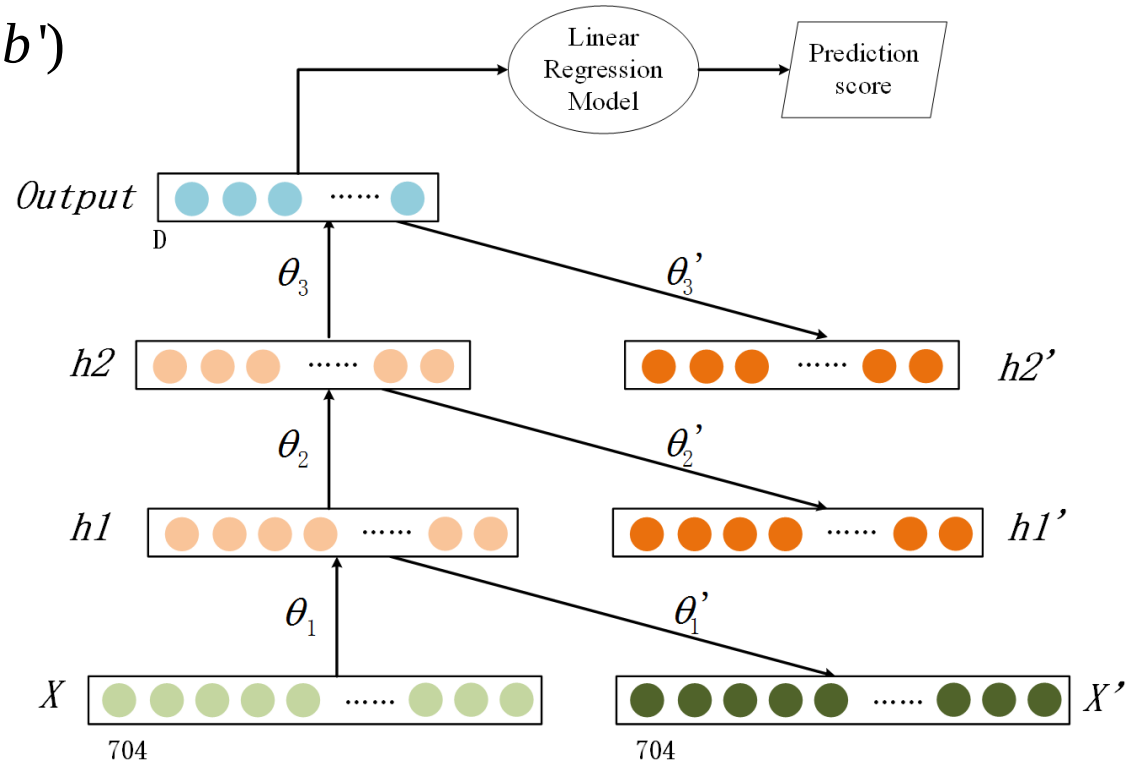
特征：微博操作行为、微博文本(“文心”)

The number of units in each layer

D_A	D_C	D_E	D_N	D_O
400	400	300	400	300

$h1_A$	$h1_C$	$h1_E$	$h1_N$	$h1_O$
550	550	600	550	600

$h2_A$	$h2_C$	$h2_E$	$h2_N$	$h2_O$
		450		450



基于微博的人格预测

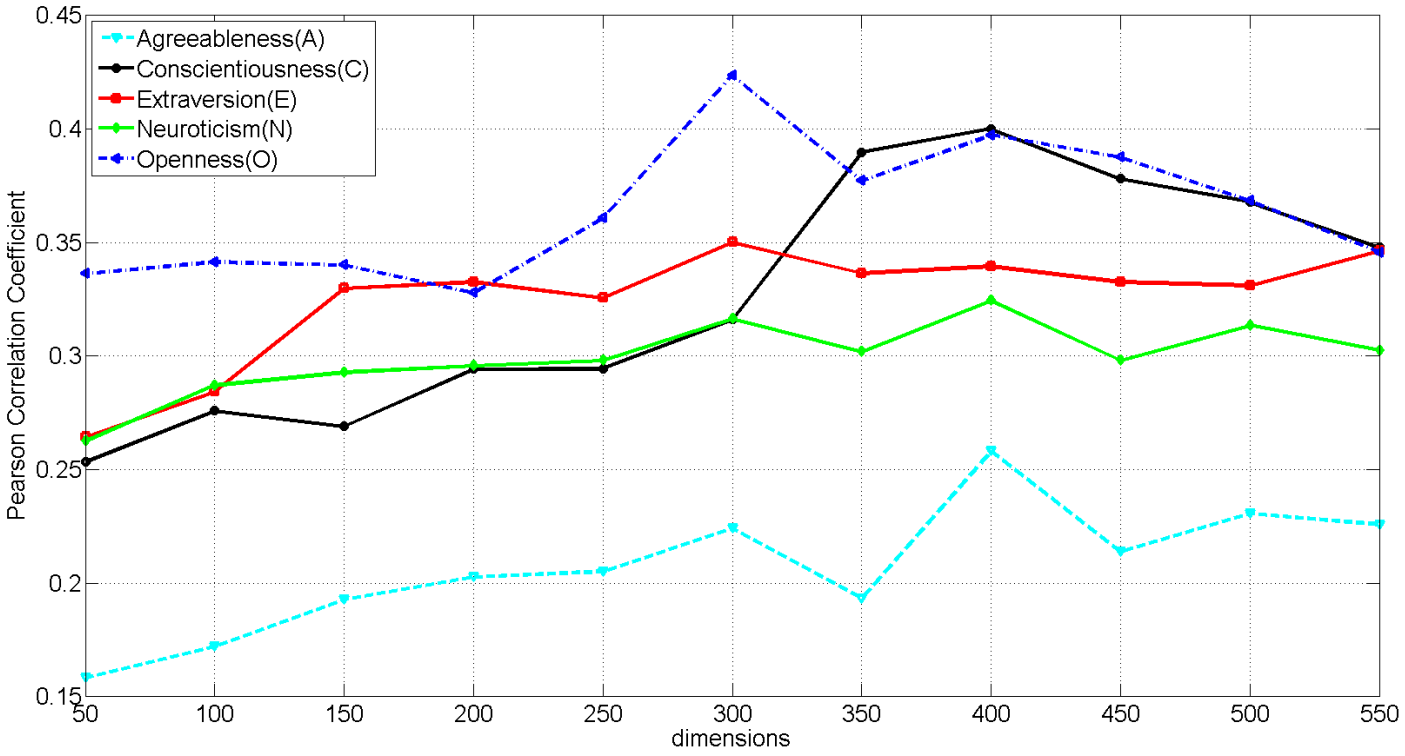
基于Stacked Autoencoders（SAE）构建面向大五人格预测的特征学习模型

预测结果（相关系数）	Original	PCA	Lasso	Stepwise	SAE
A	0.1012	0.1106	0.1209	0.1223	0.2583
C	0.1849	0.2166	0.2068	0.2639	0.4001
E	0.1044	0.1049	0.0788	0.1698	0.3503
N	0.0832	0.1235	0.0934	0.1298	0.3245
0	0.181	0.1871	0.1136	0.2246	0.4238

预测结果（RMSE）	Original	PCA	Lasso	Stepwise	SAE
A	5.6538	5.1628	5.8976	4.8421	4.7753
C	6.1335	5.6181	6.7471	5.3495	5.339
E	4.9197	5.6781	6.4940	5.276	4.8043
N	6.5591	5.9426	5.4241	5.6904	5.6188
O	7.0195	6.4579	6.0938	6.1079	5.1587

基于微博的人格预测

预实验研究：在较小数据集上利用深度学习模型提取语义特征向量，利用线性回归模型预测人格。



基于微博的人格预测

研究2：在较大数据集上提取语义特征向量，利用线性回归模型预测人格。

语义信息的获取

根据LIWC词典，计算新浪微博用户在88个维度上的语言使用情况。

以周为时间单位，每个用户的语义信息为矩阵形式 100*88。 （100周）

表征向量的构建： Stacked Autoencoders， 3层网络

无标注的数据量：9754 ； 有标注的数据量：1066

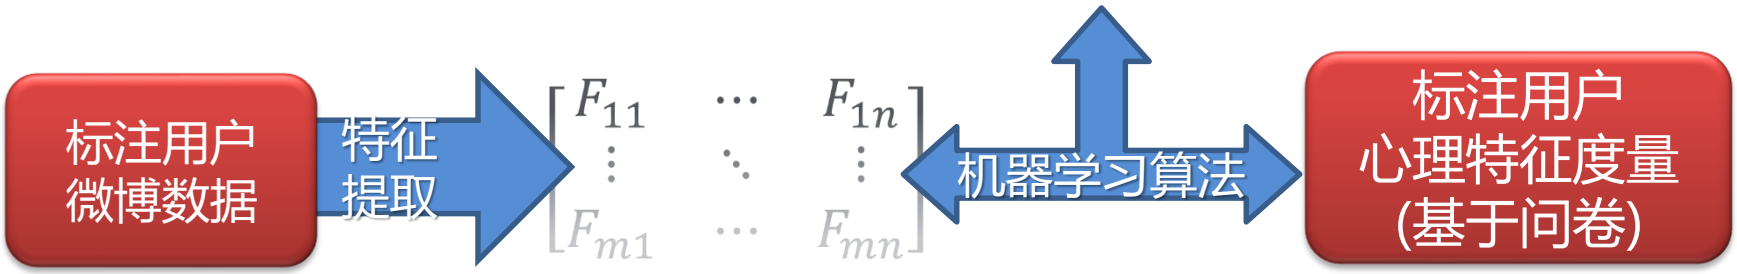
	A	C	E	O	N
label+unlabel	0.135	**0.291**	0.211	**0.245**	**0.355**
unlabel	0.107	0.201	0.231	0.238	0.348
label	0.142	0.194	**0.253**	0.148	0.306
init(no sae)	**0.179**	0.279	0.161	0.241	0.326

心理特征预测模型 » 幸福感预测 - 1

特征：
- 基本行为特征
- 语言特征
- 人口统计学信息

特征集、算法组合

算法
- Stepwise
- LASSO
- MARS
- SVR



心理特征预测模型 » 幸福感预测 - 2

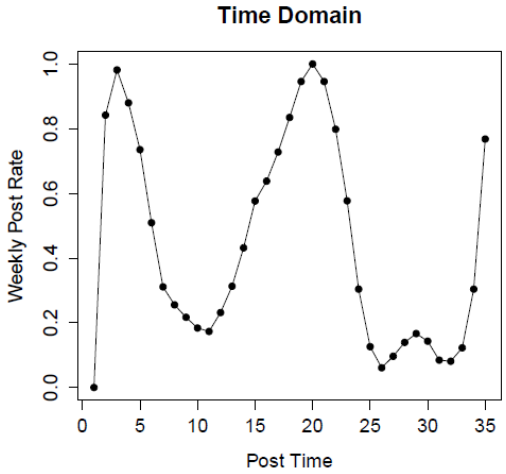
回归模型评估

- 随机猜: -0.05~0.05
- Baseline：[0.17, 0.30] (仅仅使用人口统计学信息)
- 最佳组合: [0.27, 0.60]

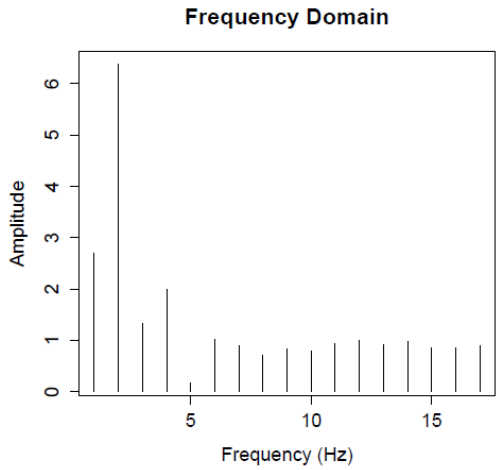
Feature Set	Algorithm	Emotional Well-being		Positive Functioning					
		P.A.	N.A.	S.A.	P.L.	E.M.	P.R.	P.G.	A.I.
B	StepWise	.24	.16	.21	.13	.22	.18	.21	.21
	LASSO	.16	.11	.15	.00	.19	.14	.00	.16
	MARS	.16	.08	.14	.04	.05	.14	.07	.13
	SVR	.19	.13	.12	.06	.17	.13	.10	.15
L [±1Week]	StepWise	.22	.16	.15	.23	.20	.16	.23	.25
	LASSO	.17	.10	.15	.16	.14	.00	.22	.16
	MARS	.19	.10	.12	.14	.15	.14	.21	.12
	SVR	.11	.09	.08	.21	.20	.12	.17	.18
D+B	StepWise	.27	.22	.23	.16	.30	.21	.20	.30
	LASSO	.20	.16	.19	.11	.24	.18	.12	.25
	MARS	.19	.06	.17	.02	.20	.12	.06	.23
	SVR	.13	.13	.11	.21	.13	.17	.24	.07
D+L [±1Week]	StepWise	.24	.19	.22	.26	.25	.20	.22	.28
	LASSO	.20	.13	.19	.23	.22	.20	.23	.25
	MARS	.16	.07	.04	.09	.06	.17	.14	.18
	SVR	.24	.11	.16	.16	.30	.22	.19	.24
B+L [±1Week]	StepWise	.23	.21	.18	.22	.18	.19	.21	.26
	LASSO	.24	.20	.11	.20	.17	.18	.24	.20
	MARS	.10	.03	.09	.07	.04	.16	.00	.10
	SVR	.18	.13	.14	.11	.22	.19	.10	.22
D+B+L [±1Week]	StepWise	.45	.26	.35	.45	.41	.45	.51	.40
	LASSO	.38	.26	.29	.34	.35	.34	.42	.35
	MARS	.40	.24	.30	.43	.45	.38	.60	.40
	SVR	.41	.27	.30	.35	.38	.39	.49	.34
Best Result		.45	.27	.35	.45	.45	.45	.60	.40
Baseline (Only D)	StepWise	.23	.17	.31	.27	.23	.30	.25	.20
	LASSO	.14	.10	.21	.14	.09	.21	.15	.13
	MARS	.16	.03	.27	.19	.07	.21	.12	.13
	SVR	.19	.14	.28	.19	.08	.22	.23	.14

1.00
.90
.80
.70
.60
.50
.40
.30
.20
.10
.00

心理特征预测模型 » 幸福感预测 - 3



(a) 时间序列时域曲线

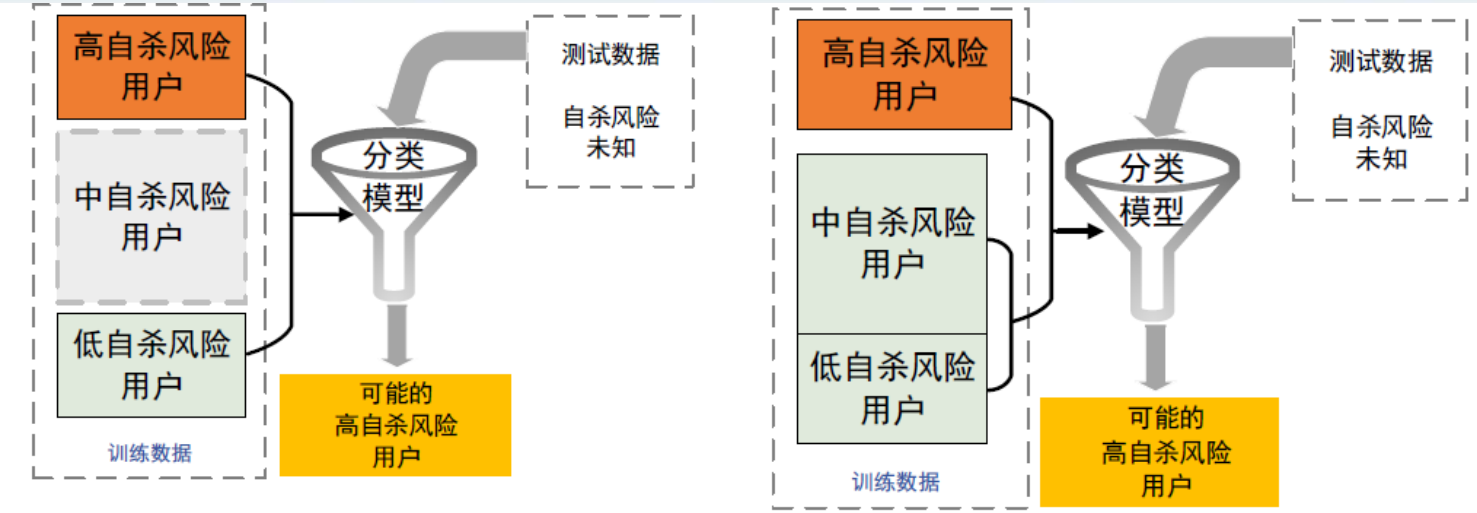


(b) 时间序列频谱

时间序列特征在预测建模中的应用

SWB Dimension	PA	NA	AI	EM	PG	PL	PR	SA
PCC	.54	.56	.46	.58	.57	.47	.46	.54
$\bar{R}^2$	.44	.49	.32	.42	.45	.37	.35	.44

心理特征预测模型 » 自杀风险预测



(a) 训练样本：（High-Low）
高风险 vs 低风险用户

(b) 训练样本：（High-Rest）
高风险 vs 其他用户

算法：Random Forest最有效

High-Low作为训练集更有效

分类问题：对高自杀风险组别
Recall 0.6~0.7

用于辅助筛查高自杀风险用户：
节省约40%的人工工作量

表 1 金庸小说创作分期及特点总结表

创作阶段	思想特点	人物特点	代表作品
第一阶段	群体本位英雄儒文化的矛盾与反复。	崇尚儒家“达则兼济天下”的胸怀的“入世者”。 如：陈家洛、郭靖、乔峰等。	《书剑恩仇录》（1955） 《碧血剑》（1956） 《射雕英雄传》（1957） 《神雕侠侣》（1959） 《雪山飞狐》（1959） 《飞狐外传》（1960） 《鸳鸯刀》（1961） 《白马啸西风》（1961）。
第二阶段	个体本位英雄文化虚无主义，崇尚道法自然。	崇尚道家的恬淡自然、反派封建礼教、向往与世无争的生活的“出世者”。 如：令狐冲、杨过、张无忌。	《倚天屠龙记》（1961） 《连城诀》（1963） 《天龙八部》（1963） 《侠客行》（1965） 《笑傲江湖》（1969） 《越女剑》（1970）。
第三阶段	反英雄主义 世俗哲学。	追求个性自由、反叛传统侠义的“玩世者”。 如：韦小宝	《鹿鼎记》（1972）

表 1 各部小说摘取人物及话语数量统计表

小说	初始文本字数	初始文本人物总数	最终文本人物数量	最终文本人物对话数
白马啸西风	54300	17	10	322
碧血剑	482145	108	39	693
飞狐外传	301258	112	30	709
连城诀	182514	37	21	1138
鹿鼎记	1499865	183	113	5060
侠客行	210065	67	43	1779
笑傲江湖	929800	160	71	2132
雪山飞狐	85724	25	16	278
倚天屠龙记	1085217	184	85	2633
鸳鸯刀	32150	15	10	220
越女剑	32090	7	7	84
总字数	8756864	1427	741	28080

金庸小说中女性人物的神经质分数显著高于于男性人物（M 男=57.18 vs M 女=70.67，t=-5.72，p=0.000＜0.005），而在其他人格倾向上无显著差异

创作阶段对人物“尽责性”倾向

第一阶段的金庸处于青年时期，年轻气盛，对事业有所追求，因而其笔下的人物更倾向于建功立业、报效社会与国家，而第二阶段后的金庸逐渐步入中年，他开始更多地关注人生自由与个体价值的实现，因而其塑造的人物体现出“个体主义”的英雄观，向往个人价值的实现，追求精神自由的人生。

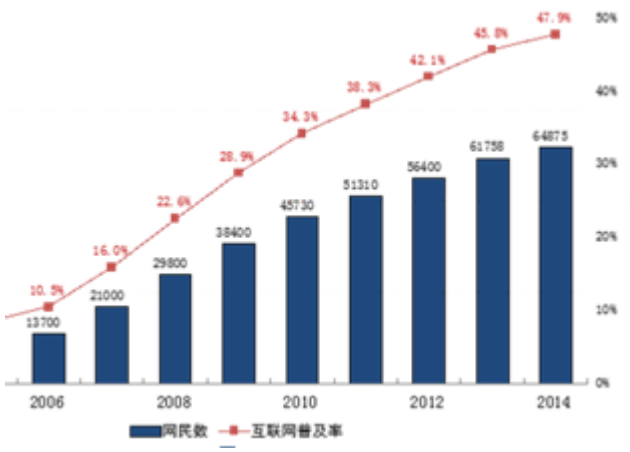
创作阶段对人物“开放性”倾向

在金庸小说创作的第二、三阶段，小说人物的开放性倾向显著地高于第一阶段人物（M1=60.34 vs M2=65.34 vs M3=71.06，F（2，736）=7.44，p=0.001＜0.005＝，体现了金庸创作早期塑造的人物更加倾向于遵守传统、常规礼教、不善变通的性格特点，而其后期塑造的人物则更具独创性，具有想象活跃、更易接受新思想的特点。

outline

- 个体心理特征计算
- 社会心态感知
- 突发事件舆情分析

社会媒体中虚拟社会是现实社会的映射



《第35次中国互联网络发展状况统计报告》

6.49	网民总数已达到6.49 亿人
5.67	网民总数同比增长5672万人
47.9	互联网普及率为47.9%
2.49	微博客用户规模为2.49亿



- 社会媒体供给网民社会行为的空间

  网络放大了群体性事件的现实社会影响力

  “马航事件”，“冰桶挑战”

- 飞速发展的社会媒体有其自己的特征

  广泛性

  特殊性

  相似性

开展社会心态感知研究的必要性



2010年底突尼斯的“茉莉花革命”



2010年9-10月反日游行



2012年7月2日，四川什邡事件

●我国社会转型期群体性事件多发

由于内部矛盾，发泄不满、表达诉求

公众的**社会心态**需要及时监测

20万

2012年以来，我国平均每年20万起群体性事件。

●社会心态

情绪、态度和价值取向的总和

指个体对社会事物的内隐倾向

心理过程与外部活动间的中介机制

300万

2005年，我国群体性事件参与人数突破300万。

开展社会心态研究的意义：提早发现社会不稳定因素，保持国家稳定繁荣。

传统的社会心态感知方法以社会调查为主

- 美国密西根大学社会研究所

  了解民意、服务于公共政策制定和行政决策

  消费者态度调查，1946年起每月一次

  全国选举研究，1948年起每两年一次

  ……

- 英国全国社会研究中心

  家庭支出调查，1957年起每年一次

  英国人选举研究，1964年起每个选举年一次

  劳动力调查，1983年起每年一次

  ……

- 中国社会科学院每年发布的《社会心态蓝皮书》

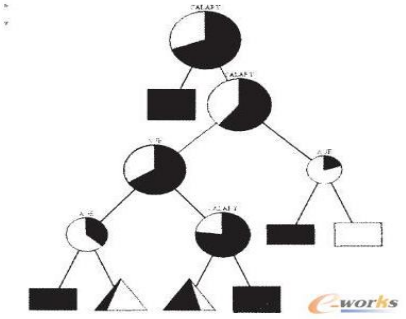


社会心态感知方法的对比

- 社会调查法
  - 问卷测评
  - 理论基础深厚
  - 测评工具结果标准

- 网络技术计算方法
  - 数据挖掘建模
  - 在技术上有优势
  - 结果实时客观，覆盖范围广

	0	1	2	3
1. 总在座位上走来走去				
2. 经常搞出一些不应该有的噪音				
3. 有要求必须立即给予满足				
4. 行为快捷(莽撞，冒昧)				
5. 好突然发脾气和有一些不可预测的行为				
6. 对批评过分敏感				
7. 易分心，注意力短暂				
8. 打扰其他同学				
9. 白日梦，好幻想				
10. 好咂嘴，生闷气				
11. 情绪改变迅速和激烈				
12. 好争吵				
13. 对权威很顺从				
14. 不安静，常常十分忙碌				
15. 易激惹，好冲动				
16. 需要老师极大的注意				



本研究集二者之长进行互补，可开展对网络新媒体下的心理学问题研究。

社会心态感知的困难点

1、先验知识库构建

用户实验



测评量表



微博用户



网络行为痕迹

2、网络数据结构化转换

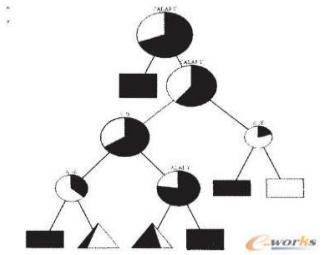
特征提取



$$\begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1N} \\ w_{21} & w_{22} & \cdots & w_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ w_{M1} & w_{M2} & \cdots & w_{MN} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_M \end{pmatrix}$$

3、感知结果的鲁棒性

交叉验证+推广验证





现有研究存在的问题

- 数据的获取
  - 手动获取
  - 线下的标注获取
- 特征提取
  - 自我陈述
  - 人工记录
- 模型建立和评估
  - 相关分析，并没有建立模型
  - 交叉验证

	数据量	数据获取	分析
Moore et al.	219	自陈	相关分析
Correa et al.	959	自陈	相关分析
Gosling et al.	292	自陈/人工记录	相关分析

样本量有限、样本覆盖范围有限，特征数有限、特征值主观，分析方法单一。

社会心态建模的理论基础

心态因素 ⟶ 网络行为痕迹



⟵ 预测







（一）心理动因客观存在，且长期存在。

（二）心理动因一旦产生，则反映在行为表现。

反其道而行之，**可对<u>用户行为痕迹</u>进行观察，对心理特征进行预测。**

例如：简历、朋友圈、人人新鲜事、微博。

社会心态感知研究-用户实验

采用增量多任务回归，对社会态度的多维度指标进行建模预测。

- 被试情况

  2013年2月至4月

  2658 新浪微博用户参与实验，被试筛选原则：

    实验前筛选：最近一个月内无微博更新或微博总数少于 500

    实验后筛选：平均答题时间少于2秒或答案呈现特定规律

  2018 个合格样本（女：892，男： 1126 ），平均年龄21.34 岁（SD=3.46）

- 社会心态标注

  城乡居民社会态度调查问卷，14个社会态度指标

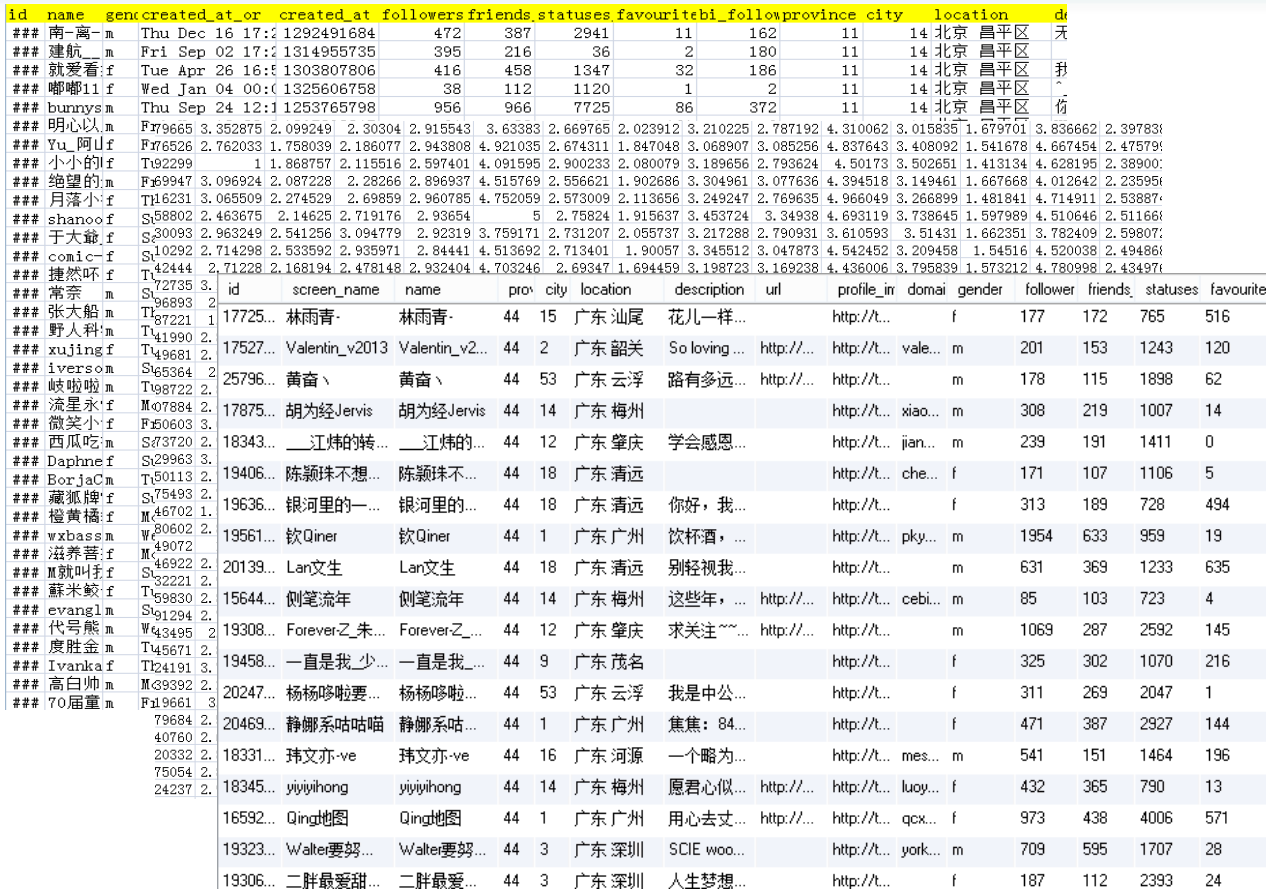
    满意度：生活、收入、社会地位、政府×2、经济×2、社会公平

    信任度：中央政府、地方政府

    群体行为：愤怒情绪、集群效能、集群行为意向、社会风险判断

现有数据情况

- 共先后三批数据
  - 新疆微博用户数据
    - 2012年9月
    - 4462个合格样本
  - 广东微博用户数据
    - 2013年4月
    - 2018 个合格样本
  - 北京微博用户数据
    - 2014年10月
    - 76780个合格样本

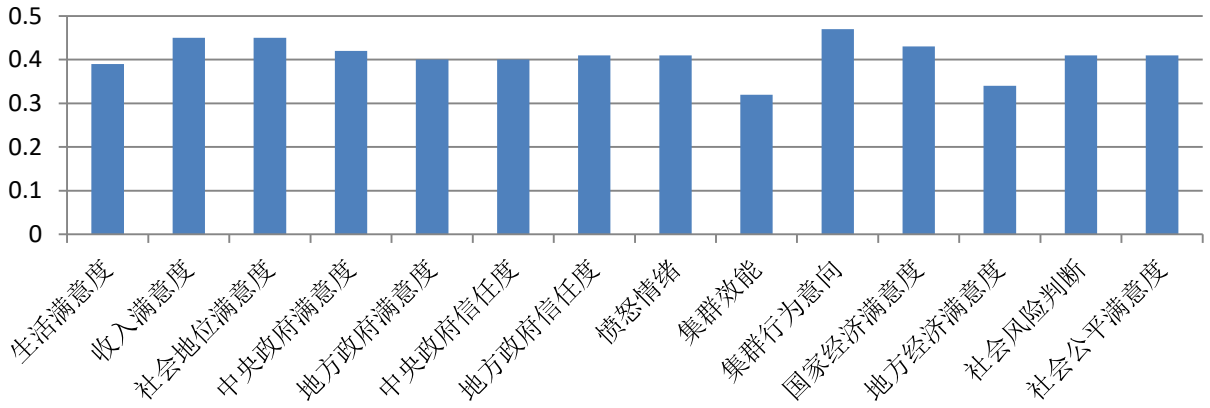


id	name	gen	created_at_or	created_at	followers	friends	statuses	favourite	bi_follow	province	city	location	de
###	南-离-	m	Thu Dec 16 17:2	1292491684	472	387	2941	11	162	11	14	北京 昌平区	无
###	建航__	m	Fri Sep 02 17:2	1314955735	395	216	36	2	180	11	14	北京 昌平区	
###	就爱看	f	Tue Apr 26 16:5	1303807806	416	458	1347	32	186	11	14	北京 昌平区	我
###	嘟嘟11	f	Wed Jan 04 00:0	1325606758	38	112	1120	1	2	11	14	北京 昌平区	
###	bunnys	m	Thu Sep 24 12:1	1253765798	956	966	7725	86	372	11	14	北京 昌平区	你
###	明心以	m	Fr	79665	3.352875	2.099249	2.30304	2.915543	3.63383	2.669765	2.023912	3.210225	2.787192	4.310062	3.015835	1.679701	3.836662	2.39783
###	Yu_阿山	f	Fr	76526	2.762033	1.758039	2.186077	2.943808	4.921035	2.674311	1.847048	3.068907	3.085256	4.837643	3.408092	1.541678	4.667454	2.47579
###	小小的	f	Tu	92299	1	1.868757	2.115516	2.597401	4.091595	2.900233	2.080079	3.189656	2.793624	4.50173	3.502651	1.413134	4.628195	2.38900
###	绝望的	m	Fe	69947	3.096924	2.087228	2.28266	2.896937	4.515769	2.556621	1.902686	3.304961	3.077636	4.394518	3.149461	1.667668	4.012642	2.23595
###	月落小	f	Th	16231	3.065509	2.274529	2.69859	2.960785	4.752059	2.573009	2.113656	3.249247	2.769635	4.966049	3.266899	1.481841	4.714911	2.53887
###	shanoo	f	Su	58802	2.463675	2.14625	2.719176	2.93654	5	2.75824	1.915637	3.453724	3.34938	4.693119	3.738645	1.597989	4.510646	2.51166
###	于大爺	f	Sa	30093	2.963249	2.541256	3.094779	2.92319	3.759171	2.731207	2.055737	3.217288	2.790931	3.610593	3.51431	1.662351	3.782409	2.59807
###	comic-	f	Su	10292	2.714298	2.533592	2.935971	2.84441	4.513692	2.713401	1.90057	3.345512	3.047873	4.542452	3.209458	1.54516	4.520038	2.49486
###	捷然吓	f	Tu	42444	2.71228	2.168194	2.478148	2.932404	4.703246	2.69347	1.694459	3.198723	3.169238	4.436006	3.795839	1.573212	4.780998	2.43497
###	常奈	m	Su	72735	3.													
###	张大船	m	Th	96893	2													
###	野人科	m	Tu	87221	1													
###	xujing	f	Tu	41990	2.													
###	iverso	m	Su	49681	2.													
###	岐啦啦	m	Tu	65364	2													
###	流星永	f	M	98722	2.													
###	微笑小	f	Fa	07884	2.													
###	西瓜吃	m	Sa	50603	3.													
###	Daphne	f	Su	73720	2.													
###	BorjaC	m	Ti	29963	3.													
###	藏狐牌	f	Su	50113	2.													
###	橙黄橘	f	M	75493	2.													
###	wxbass	m	We	46702	1.													
###	滋养菩	f	M	80602	2.													
###	M就叫我	f	Su	49072														
###	蘇米鲛	f	Tu	46922	2.													
###	evangl	m	Su	32221	2.													
###	代号熊	m	We	59830	2.													
###	度胜金	m	Tu	91294	2.													
###	Ivanka	f	Th	43495	2													
###	高曰帅	m	M	45671	2.													
###	70届童	m	Fu	24191	3.													
				39392	2.													
				19661	3													
				79684	2.													
				40760	2.													
				20332	2.													
				75054	2.													
				24237	2.													

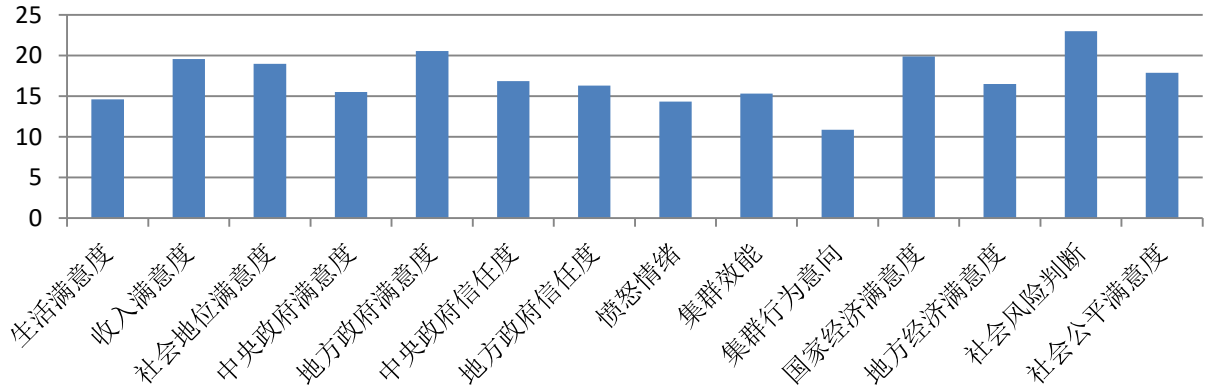
id	screen_name	name	pro	city	location	description	url	profile_in	domai	gender	follower	friends	statuses	favourite
17725...	林雨青·	林雨青·	44	15	广东 汕尾	花儿一样...		http://t...		f	177	172	765	516
17527...	Valentin_v2013	Valentin_v2...	44	2	广东 韶关	So loving ...	http://...	http://t...	vale...	m	201	153	1243	120
25796...	黄奋丶	黄奋丶	44	53	广东 云浮	路有多远...	http://...	http://t...		m	178	115	1898	62
17875...	胡为经Jervis	胡为经Jervis	44	14	广东 梅州			http://t...	xiao...	m	308	219	1007	14
18343...	___江炜的转...	___江炜的...	44	12	广东 肇庆	学会感恩...		http://t...	jian...	m	239	191	1411	0
19406...	陈颖珠不想...	陈颖珠不...	44	18	广东 清远			http://t...	che...	f	171	107	1106	5
19636...	银河里的一...	银河里的...	44	18	广东 清远	你好，我...		http://t...		f	313	189	728	494
19561...	钦Qiner	钦Qiner	44	1	广东 广州	饮杯酒，...		http://t...	pky...	m	1954	633	959	19
20139...	Lan文生	Lan文生	44	18	广东 清远	别轻视我...		http://t...		m	631	369	1233	635
15644...	侧笔流年	侧笔流年	44	14	广东 梅州	这些年，...	http://...	http://t...	cebi...	m	85	103	723	4
19308...	Forever之_朱...	Forever之_...	44	12	广东 肇庆	求关注~~...	http://...	http://t...		m	1069	287	2592	145
19458...	一直是我_少...	一直是我_...	44	9	广东 茂名			http://t...		f	325	302	1070	216
20247...	杨杨哆啦要...	杨杨哆啦...	44	53	广东 云浮	我是中公...		http://t...		f	311	269	2047	1
20469...	静娜系咕咕喵	静娜系咕...	44	1	广东 广州	焦焦：84...		http://t...		f	471	387	2927	144
18331...	玮文亦-ve	玮文亦-ve	44	16	广东 河源	一个略为...		http://t...	mes...	m	541	151	1464	196
18345...	yiyiyihong	yiyiyihong	44	14	广东 梅州	愿君心似...	http://...	http://t...	luoy...	f	432	365	790	13
16592...	Qing地图	Qing地图	44	1	广东 广州	用心去丈...	http://...	http://t...	qcx...	f	973	438	4006	571
19323...	Walter要努...	Walter要努...	44	3	广东 深圳	SCIE woo...		http://t...	york...	m	709	595	1707	28
19306...	二胖最爱甜...	二胖最爱...	44	3	广东 深圳	人生梦想...		http://t...		f	187	112	2393	24

研究结果

相关性



误差率



●模型效果

相关性：0.39~0.47

平均误差：17.17%

算法	相关性	平均误差率
线性回归	0.11~0.25	21.5%
神经网络	0.21~0.45	19.75%
增量多任务回归	**0.39~0.47**	**17.17%**

模型正确率在80%以上，且达到中等相关。可用来进行大范围的推广计算。

广东省结果：中山市社会满意度变化曲线

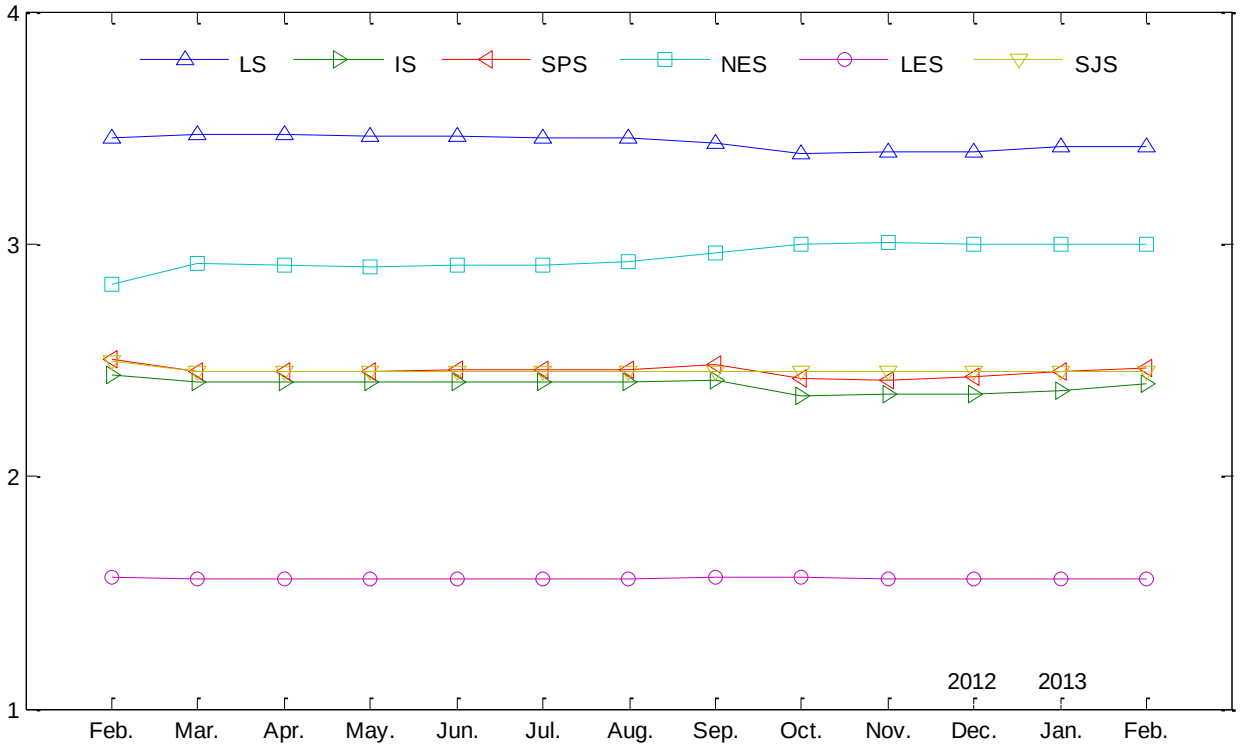


图. 中山市群体社会态度变化曲线

通过社会媒体下的社会心态感知研究，可刻划出地区公众社会心态的变化趋势。

验证：广东经济指标与社会满意度

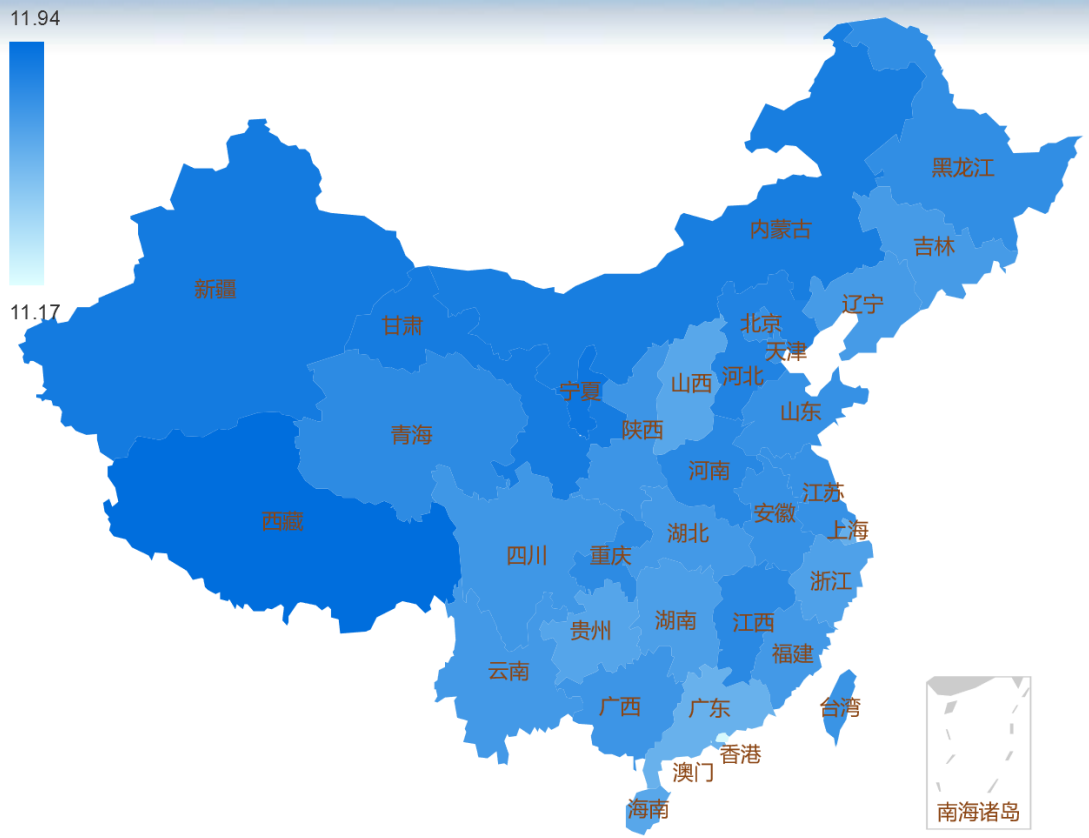
以城市为单位，计算2013年经济指数排名序列和满意度排名序列的相关性。

表. 经济指标与满意度的相关系数

经济指标	生活满意度	收入满意度	社会地位满意度	国家经济满意度	地方经济满意度	社会公平满意度
生产总值	.06	.10	-.26	.05	.15	-.12
生产总值增长率	-.21	-.11	.29	-.14	.41	.38
人均生产总值	.15	.13	.26	-.08	**.66****	.25
农业生产总值	.04	.15	.08	-.16	**.58****	.04
粮食产量	-.04	-.02	.18	-.08	.45*	.38
甘蔗产量	.30	.31	.38	.08	.39	.39
花生产量	.11	.08	.32	-.15	.49*	.39
蔬菜产量	-.21	.07	.04	-.04	**.60****	.18
生猪年末存栏头数	.07	.04	.06	-.16	**.59****	.16
肉猪出栏头数	.08	.02	.00	-.19	**.58****	.09
猪肉产量	.07	.02	-.01	-.18	**.58****	.09
社会消费品零售总额	-.19	-.01	.32	-.17	.45*	**.54***
批发零售贸易业零售额	-.19	-.01	.33	-.15	.44*	**.54***
在岗职工人数	.18	.18	.03	.26	.19	.08
在岗职工收入	.16	.15	-.06	.25	.09	-.05
在岗职工人均收入	.03	-.09	.15	-.11	.51*	.33

通过与宏观经济指标的相关性计算，表明利用微博数据预测的社会心态是可靠的。*

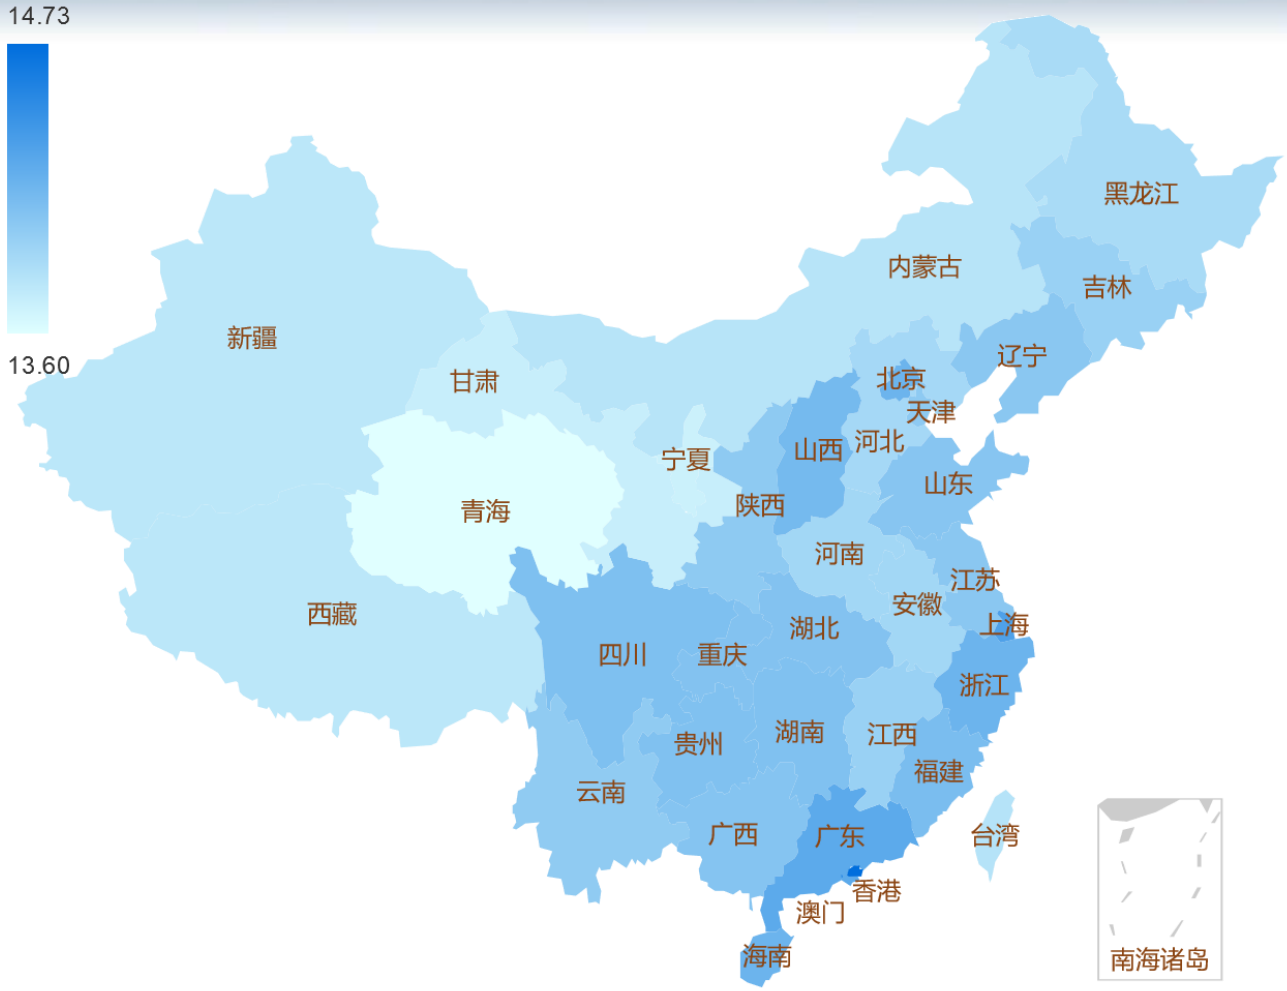
“Purpose in Life” across China



Purpose in Life: High scorers have goals and a sense of directedness in life, they feel that there is meaning to their life both currently and in the past, they hold beliefs that give life purpose, and they have aims and objectives for living.

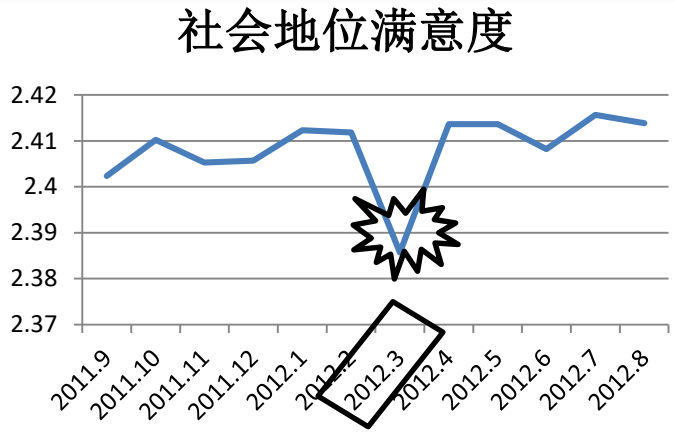
生命意义量表: 生活质量、生命价值、生活目标、生活自由

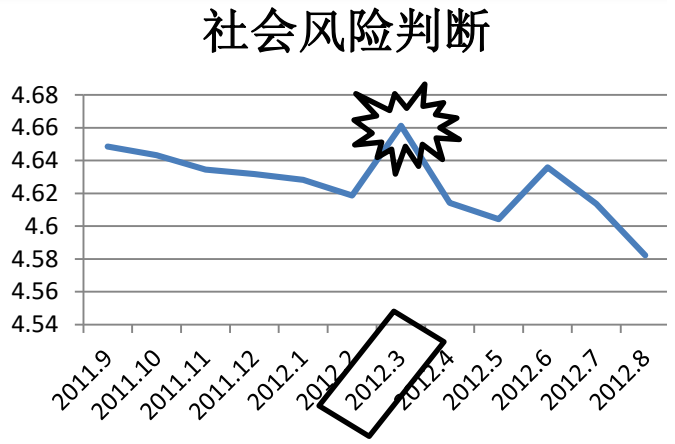
“Life of Satisfactory” across China

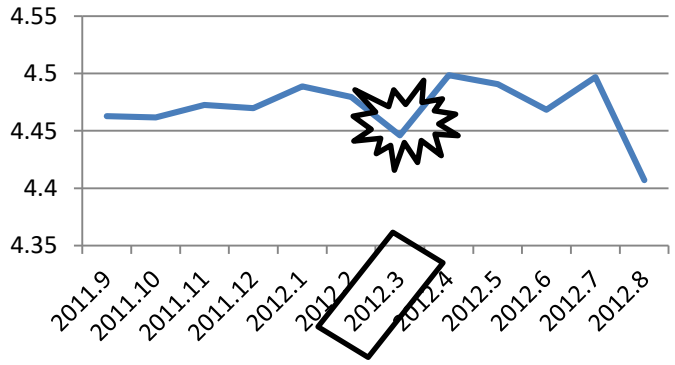


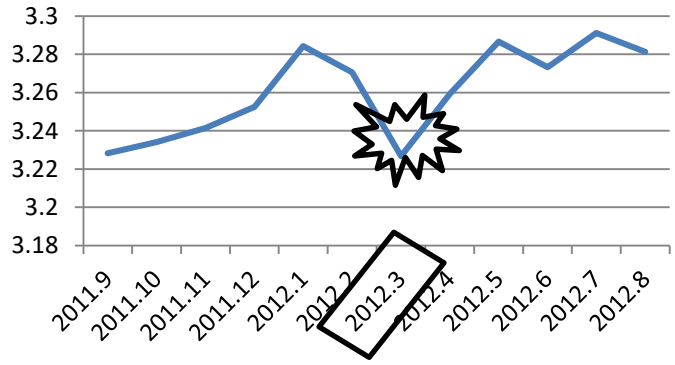
Life of Satisfactory(生活满意度)

新疆：暴恐事件与社会满意度











人民网 >> 时政 >> 滚动新闻

新疆叶城“2·28”暴力恐怖案件一审公开审理宣判

2012年03月26日20:59　　手机看新闻

打印 网摘 纠错 商城 关注 126.9万 分享 推荐 字号

2012年3月26日，喀什地区中级人民法院一审公开开庭审理被告人阿布都克热木·马木提暴力恐怖案并当庭宣判，以组织、领导恐怖组织罪、故意杀人罪数罪并罚，判处其死刑，剥夺政治权利终身。

法院审理查明，被告人阿布都克热木·马木提自2011年7月至2012年2月，以非法“台比力克”活动等手段传播宗教极端、暴力恐怖思想，积极物色人员，形成以其为首、吾布力卡斯木·买买提、托合提库瓦尼·买买提等9人参加的暴力恐怖组织，并多次密谋、指挥组织成员踩点，确定恐怖袭击目标，策划暴力恐怖行动方案。2012年2月28日上午，被告人阿布都克热木·马木提在其家中召集恐怖组织成员，确定实施暴力恐怖行动，进行编组、分工，分发刀、斧等犯罪工具，演示实施恐怖袭击的方法。当日下午18时许，带领恐怖组织成员到达叶城县幸福路步行街，持刀、斧疯狂砍杀无辜群众，当场致13人死亡，16人受伤（其中2人经抢救无效死亡）。被告人阿布都克热木·马木提被当场抓获，7名暴力恐怖分子被击毙，另1名被击伤后抢救无效死亡。在事件处置过程中，1名联防队员牺牲，4名公安民警受伤。

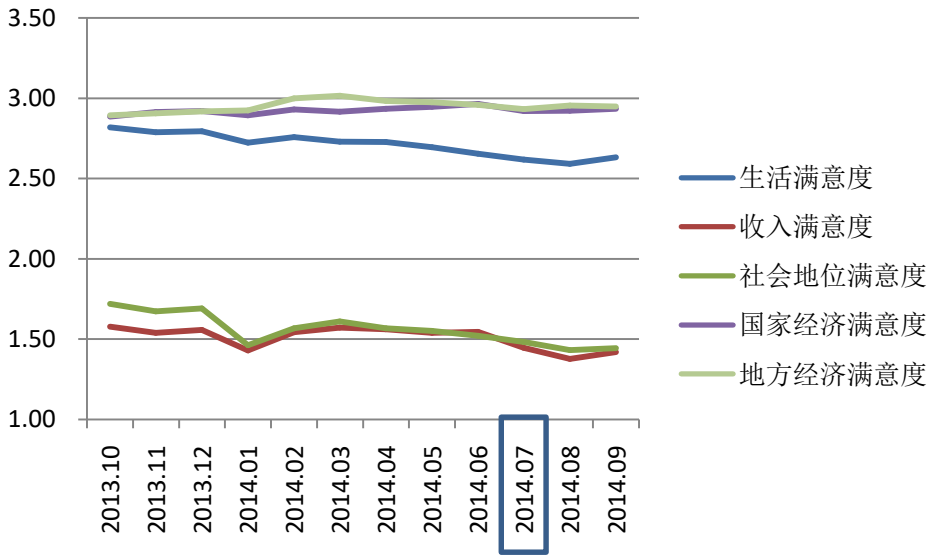
上述犯罪事实，有目击证人证言、被害人陈述、收缴的作案工具、现场视频资料、法医尸检、伤情鉴定、现场勘查笔录等证据证实，被告人也供认不讳。

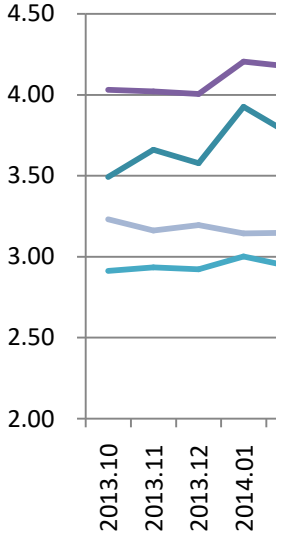
2012年2月28日，新疆“2·28”暴力恐怖案件，15人死亡，14人受伤。

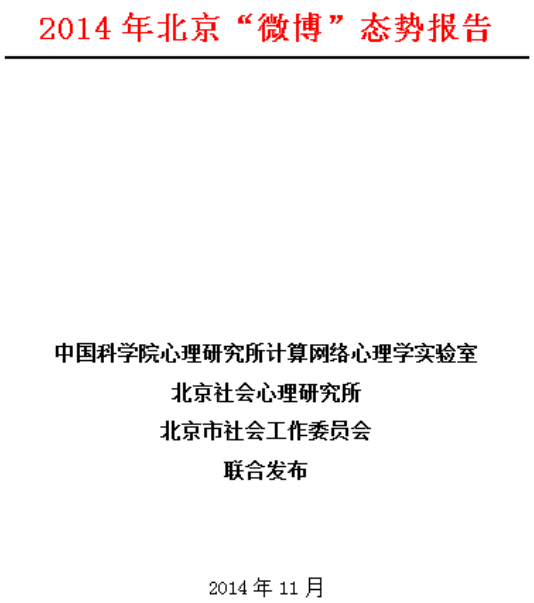
暴恐等群体性事件的发生会影响群体社会态度的变化。
开展群体社会态度的实时计算对事件的后续处理有指导意义。

政策制定过程中的社会态度变化

●针对公交、地铁票价调整听证会
2014年7月份，公交票价改革公开征集意见活动







●听证会，作为吸取民众意见而制定国家或地区政策的方
的透明度，期间老百姓对政府工作的满意度提升。

●地铁公交价格上升，增加了百姓生活成本，**群体生活、收入、经济和社会地位的满意度降低。**

*2014年北京“微博”态势报告. (2014). 中科院心理所、北京社会心理所、北京社工委联合发布.

outline

个体心理特征计算

社会心态感知

突发事件舆情分析

网络大数据给社会治理带来新机遇

网络大数据是什么？

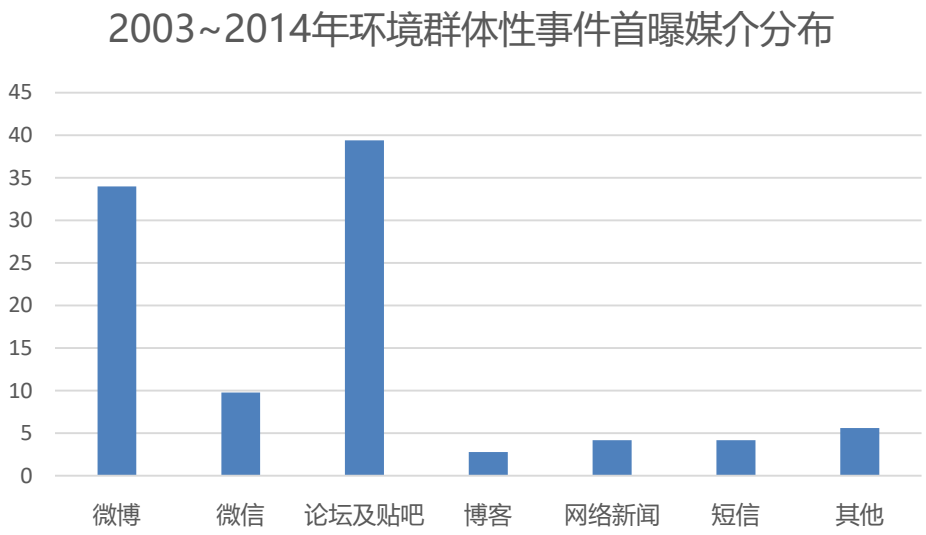
网络大数据能做什么？



- 监测社会事件
  - 今天有哪些社会事件发生？
  - 什么时间？什么地点？什么事件？谁在参与？

- 事件分级预警
  - 这事严重吗？
  - 这事影响大吗？
  - 这事群众意见大吗？
  - 这事会怎样发展？

监测社会事件的最佳数据源



——上海交通大学舆情研究实验室



无处不在的微博

相比记者报道：

- 数据量大（超过2亿潜在“记者”）
- 实时性（手机微博实时更新）

挑战一　微博信息的异质性

Hashtag: 话题



天蓝若空2020

#拯救湿地，迫在眉睫# 下图中为胶州湾湿地的生态问题，图片拍摄于2015年12月20日，敬请有关方面关注。什么也不说了。“胶州湾保护条例”？http://t.cn/RZR2QFn 六问青岛市林业局 @青岛发布 @青岛环保 @胶州环保 @国家林业局 @山东环境 @生态齐鲁网 @生态梦人 @不浪费2 @鹊言湖语 @山东省发展改革委



5月1日20:47 来自 微博 weibo.com

@用户

地理位置URL



晴暖依旧

恕我才疏学浅，大烟囱往外冒火是怎么个意思呢？[illegible]还在喷，火红一片啊！@城阳交警流亭中队 @青岛交通广播FM897 @青岛茅山老道 隆海路



5月14日20:19 来自 HTC One 时尚版

挑战二　网络语言的多态性

【世界观】所谓"坏人心中也有杆称"，中国特权阶层口头上"严正抗议"某国，但深知比自己的国家理性健康得多，尽管大力声援北朝鲜、古巴等"内政不容干涉"，但心如明镜不会移亲或财产转移到那里，甚至俄罗斯也不考虑。特权集团首选的移亲国家是美国，加拿大，澳大利亚等，口不对心排外的民主国家。



"抗议"？

下班路上，环湾高速旁有一家化工厂烟囱在喷火，排放的气体和灰尘肯定污染环境，为了我们共同的青岛，有关部门是不是应该管管@恋青岛 @青岛同城会 @青岛微生活 @QTV-2生活在线 @青岛私家车电台FM964



5月14日 17:38 来自 Android客户端

"管管"

挑战三　事件信息的稀疏性

1. 王靓雅 付辛博
2. 锤子手机
3. 王俊凯 聊不下去了
4. 东北台风
5. 克拉恋人 双男主
6. 聂远
7. 锤子
8. 沪指 破3000点
9. 印花税
10. 陈欧

基于词频Burst：与关注事件无关



关键词匹配：同词异义



babbles：闲言碎语

传统方法的不足

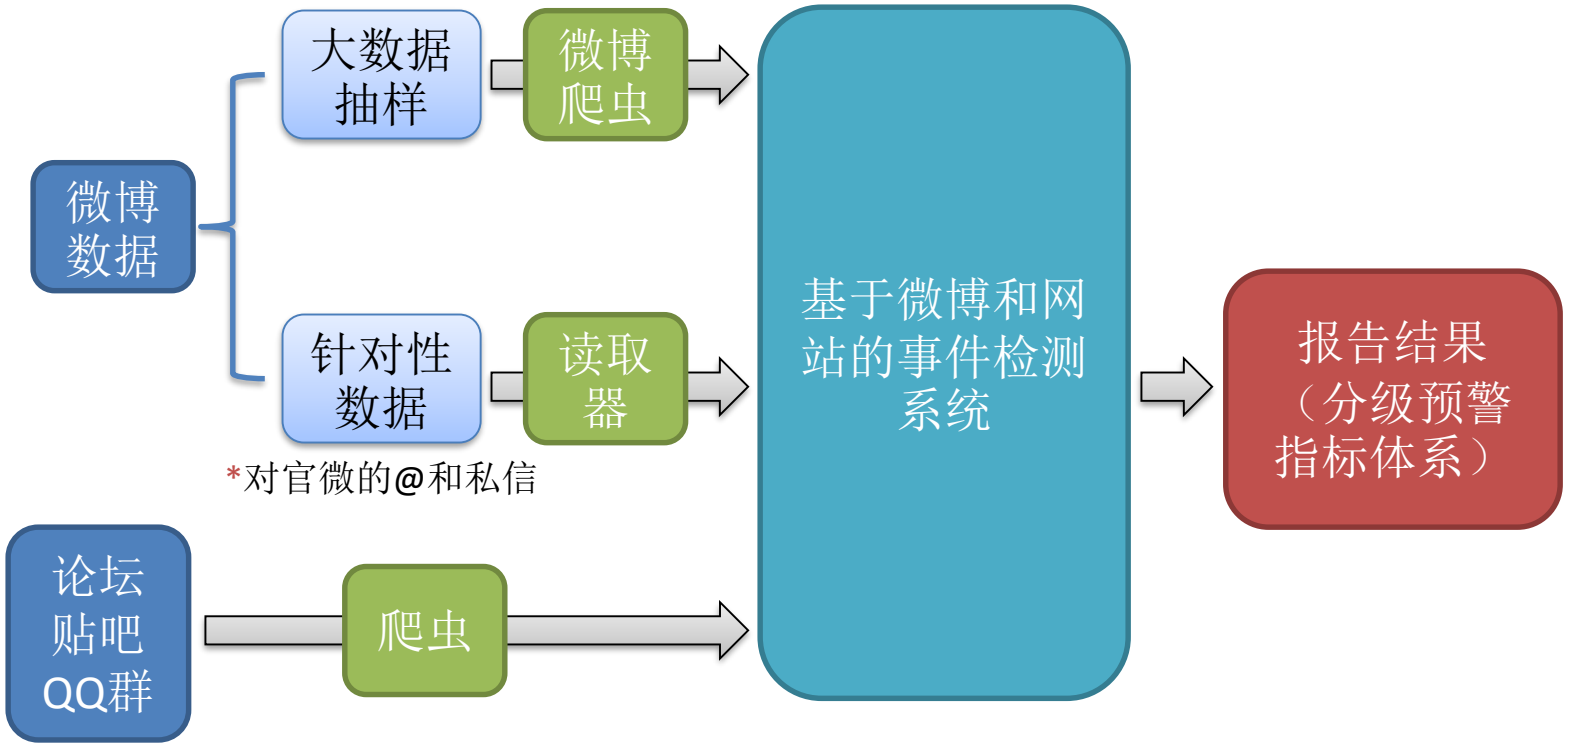
人工检视 + 基本关键词过滤

检索范围有限

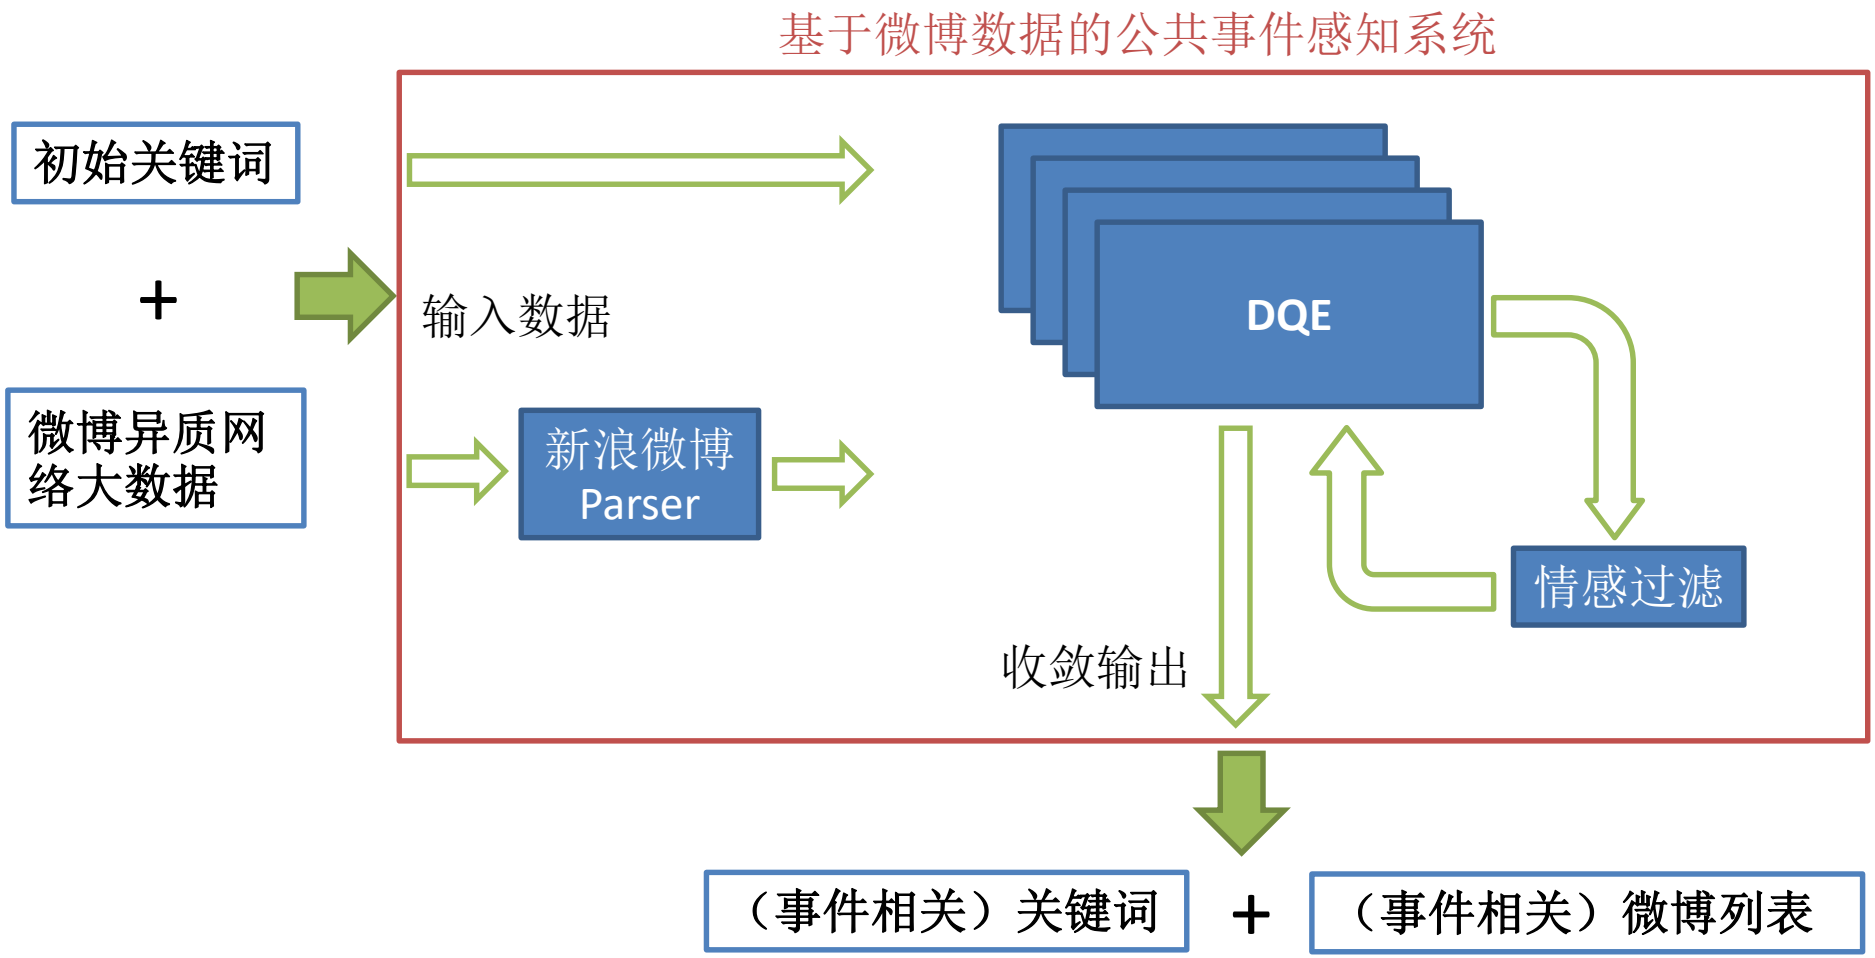
人力耗费巨大
反应速度受限

缺少分级预警，无法满足处置决策需求

分级预警辅助决策系统架构



基于微博和网站的事件检测系统 – 架构



事件检测技术 – DQE

Input: Seed Query $\mathcal{Q}_0 = \left\{\left(v_i, w(v_i)^{(0)}\right)\right\}_{i=1}^{M}$, Twitter subcollection $\mathcal{C}_p$

Output: Expanded Query $\mathcal{Q}_p$

Initialize T, F, T_r^0, and $w(T)$

Set Φ via Equation 3 and 4

Set $k=0$

repeat

  repeat

    $Swap\left(\min\left(w(T_r^k)^{(k)}\right), \max\left(w(T-T_r^k)^{(k)}\right)\right)$

    $\sigma = \min\left(w(T_r^k)^{(k)}\right) - \max\left(w(T-T_r^k)^{(k)}\right)$

  until $\sigma \geq 0$;

  $w(F)^{(k)} = D_F \cdot A_{F,T} \cdot w(T)^{(k-1)}$

  $w(T)^{(k)} = \Phi \cdot \left(A'_{F,T} \cdot w(F)^{(k)} + \beta A_T \cdot w(T)^{(k-1)}\right)$

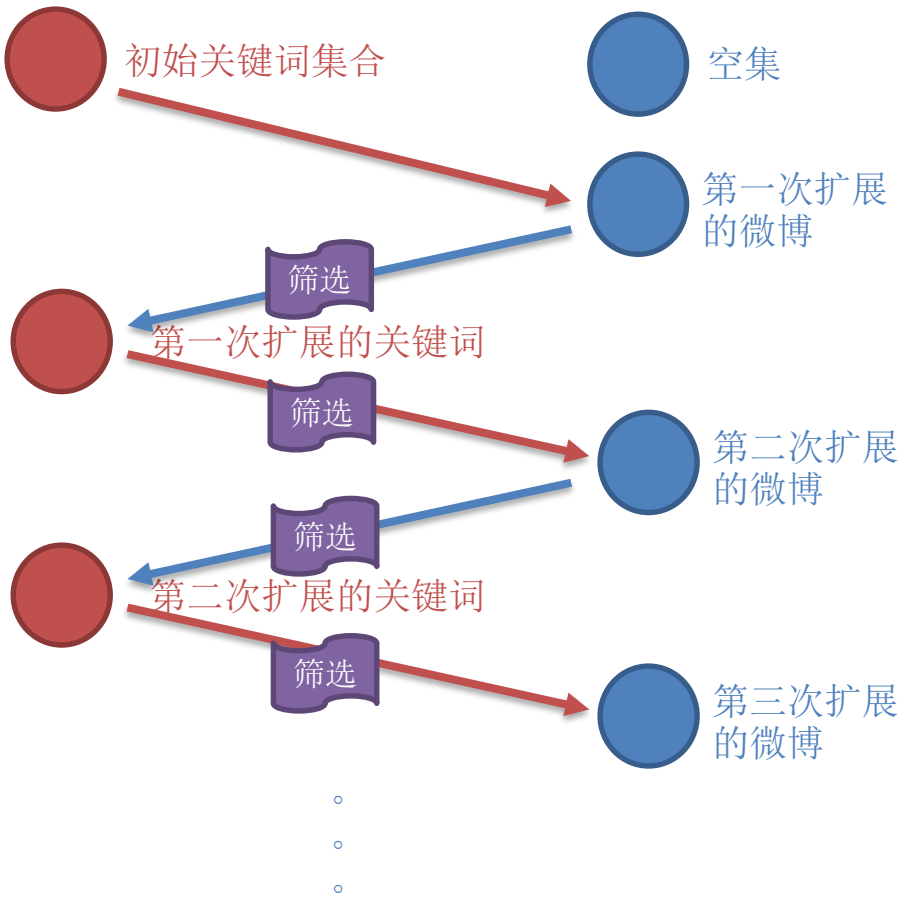
  $\sigma = \max\left(w(T-T_r^k)^{(k)}\right) - \min\left(w(T_r^k)^{(k)}\right)$

  $k = k+1$

until $\sigma \leq 0$;

$w(F_r) = \left\{w(v_i)^{(k)} \in w(F)^{(k)} | v_i \in F_r \subseteq F\right\}$

$\mathcal{Q}_p = \{(v_i, w(v_i)) | v_i \in F_r, w(v_i) \in w(F_r)\}$.



事件检测技术 – 情绪过滤



乐	0
好	0
怒	**3**
哀	**2**
惧	0
恶	0

√

目标事件（Y/N）？



乐	**3**
好	**1**
怒	0
哀	0
惧	0
恶	0

X

事件检测技术 – 情绪过滤与DQE综合运用的优势

理论上：
- 可以针对特定领域
- 可以利用新浪微博的异质数据
- 可以应对变化的网络语言
- 考虑了特定领域事件的情绪差异

实际上：
- 准确性
- 参数敏感性
- 地理距离敏感性
- 收敛速度

均表现优异

分级预警指标体系

事件信息	事件的时间、地点、内容、关键要素等，事件原始信息摘要。
事件类型	个体事件 VS. 公共事件。
影响潜力	事件的煽动性，事件所反映的民众情绪与态度。
次日预警	次日发生公共事件或群体事件的可能性。
事件热度	事件在网络环境中传播的广度、热议的程度。
社会态度	事件关注者的综合社会态度。

事件分级预警技术-基于心理语义的影响潜力分析

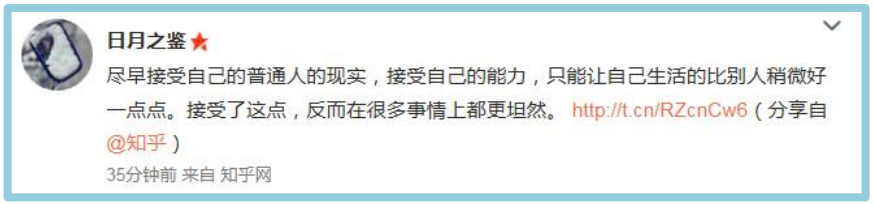
简体中文化
适用于简体中文环境的基本词库

网络词扩展
适用于社交网络文本的扩展词库

效度检验
有效性达到或超过国外同类研究

“文心”心理语义词典

简体中文分词系统



输入中文文本

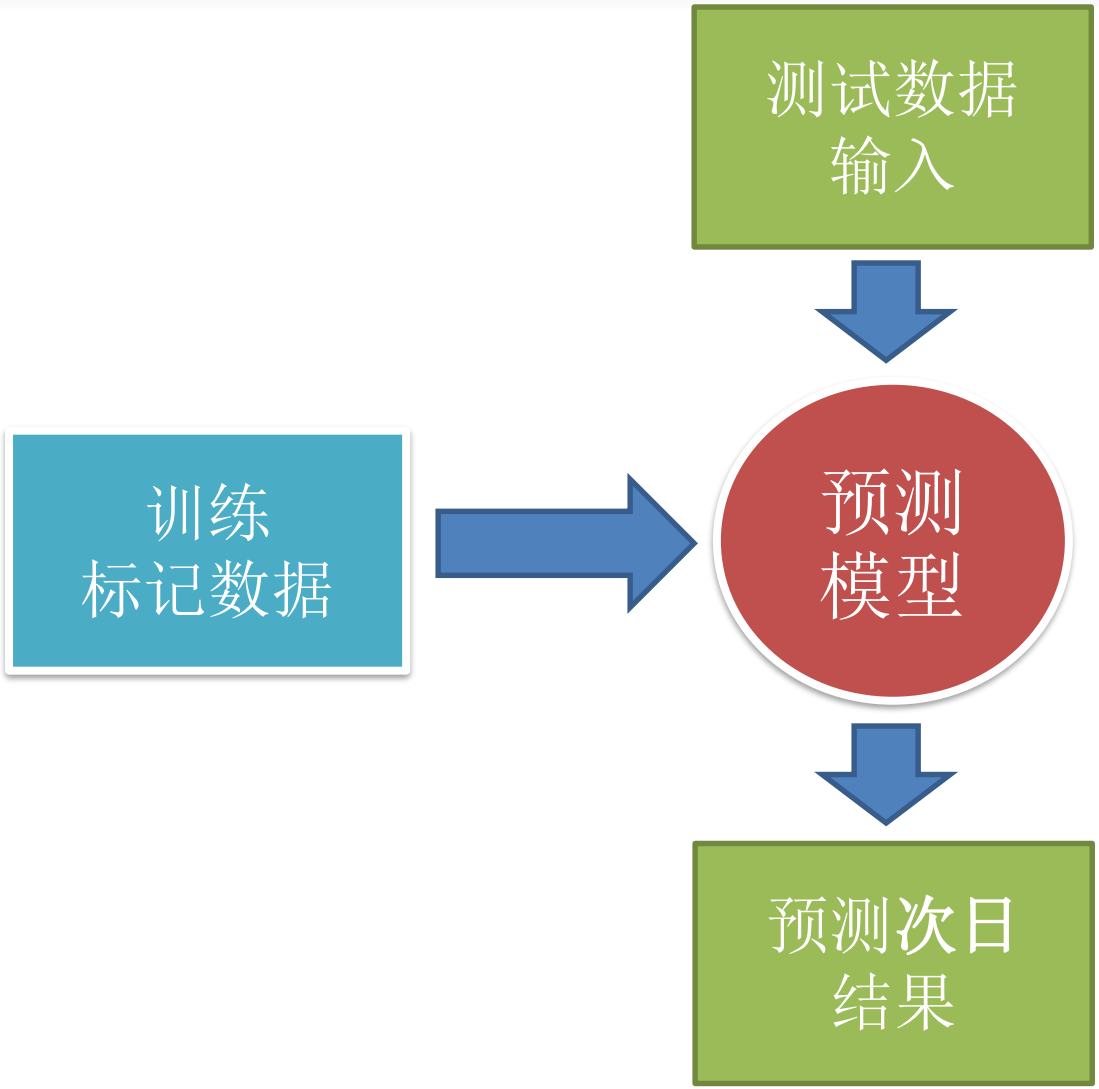
情绪表达: 积极, 消极, 焦虑, 愤怒...

认知过程: 洞察, 探因, 比较, 犹豫...

个人关注: 身体, 金钱, 成就, 死亡...

输出心理语义

事件分级预警技术-次日预警模型



机器学习算法：

无监督学习，

半监督学习，

多任务学习，

……

青岛天价虾事件的舆情分析





	事件	处置	段子	类似事件	影响
10月5日	3	-	1	-	-
10月6日	3	2	-	1	-
10月7日	1	-	3	4	1
10月8日	-	1	4	4	-
10月9日	-	2	3	3	1
10月10日	-	3	1	3	-
10月11日	-	-	2	-	-
10月12日	-	-	1	1	-

BBC报道

新浪微博调查

事件本身的表述

对事件处置的关注

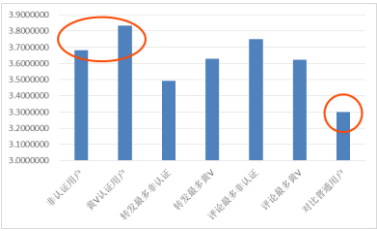
段子的爆发与狂欢

类似事件大吐槽

从传播内容看，段子与情绪发泄式的调侃吐槽是主流，情绪应对为主，而非问题应对。

积极参与者的心理特征

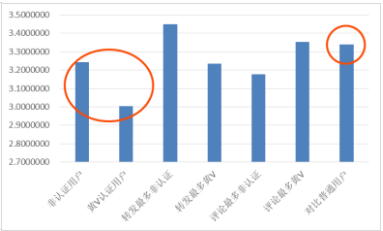
对比事件积极传播的一般用户和大V用户，以及普通微博用户的社会心态

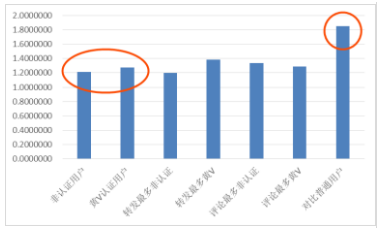

生活满意度


收入满意度

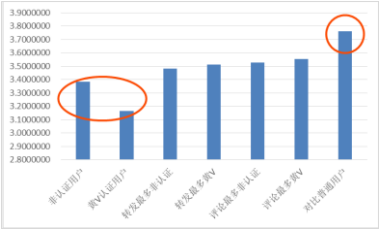

社会地位满意度


愤怒情绪

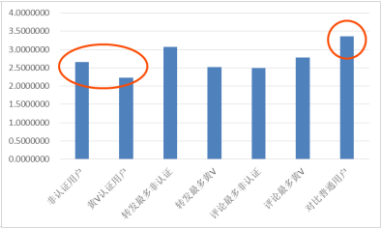

国家政府满意度


地方政府信心


国家经济满意度


地方经济满意度


社会风险判断


集群效能

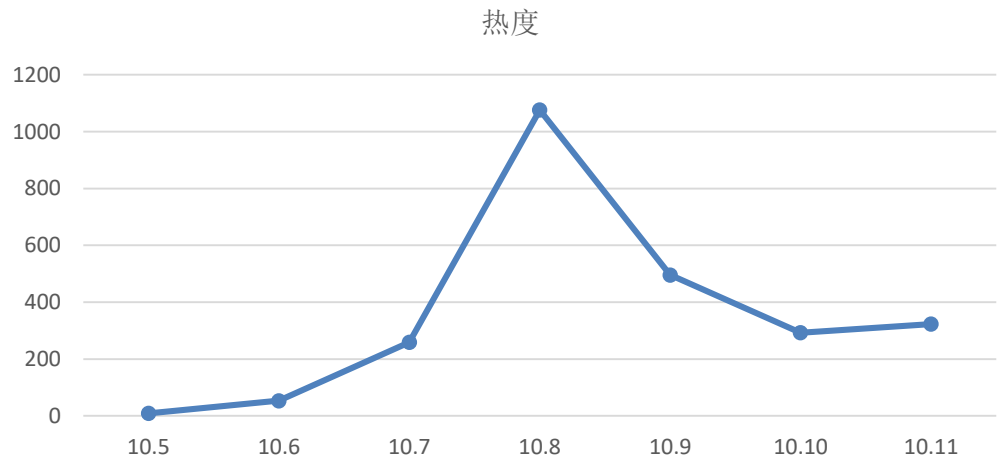
积极传播者的心理特征：

- 收入较好，有一定社会地位，对个人的生活比较满意，愤怒情绪较少。
- 对政府不太满意、信心不足，不满经济发展现状，认为社会存在较高风险，且有些无力改变。

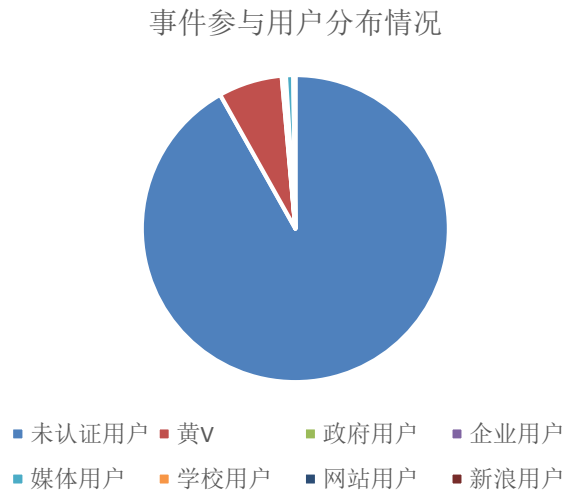
大V相对于普通用户，上述特点更甚。

1) NBA莫雷事件

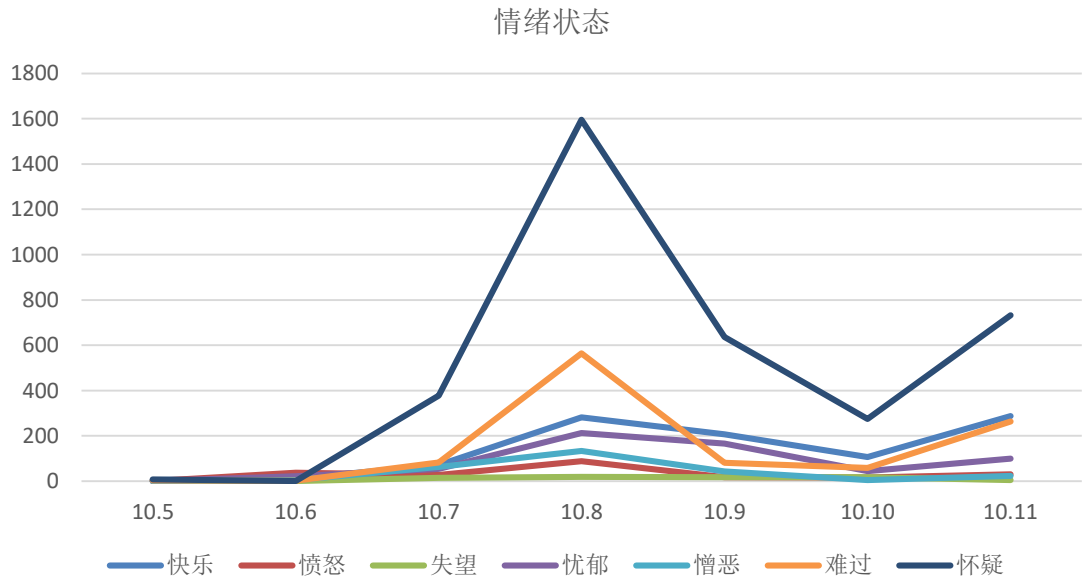
在莫雷事件中经计算我们发现参与该话题讨论的微博条数共有2510条，在一周的观察周期内具体的发博条数变化如下图所示。



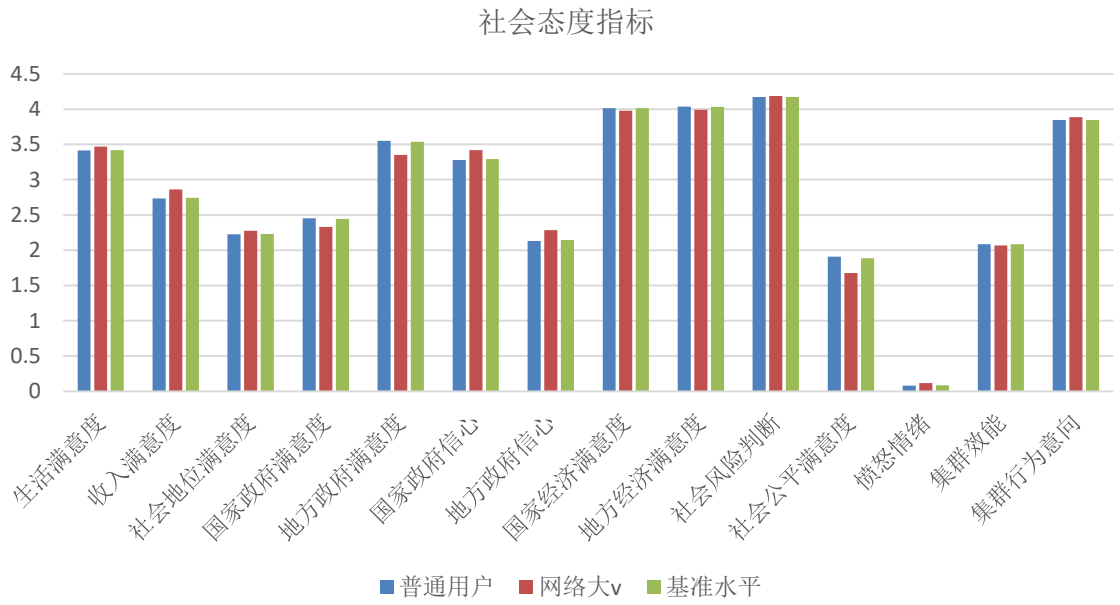
参与莫雷事件讨论的人数共有2037人，其中普通用户占据了最大的比例，为92%；而发言的黄V用户的人数为137人，占到了总参与人数的7%，也在一定程度上带动了用户对于该事件的讨论。具体的用户分布情况如下表所示。



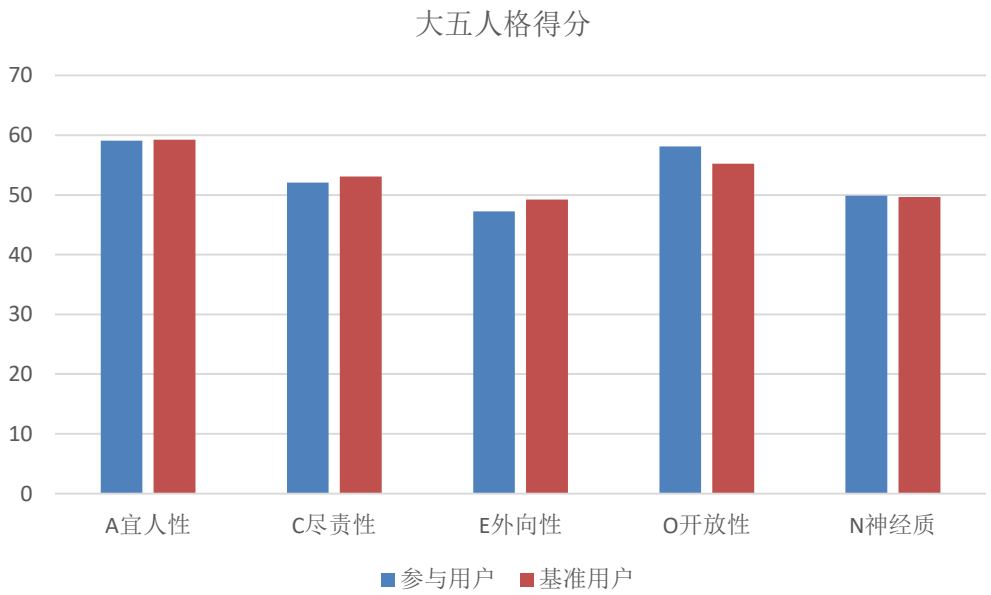
通过对用户发布的事件相关微博的言论分析，我们得到了在事件发生一周内用户的情绪分布状况，如下图所示。经观察我们可以发现其和话题的讨论热度发展趋势基本一致，用户的情绪也是在事件发生三天后达到了最高点。其中大部分用户对该事件持怀疑态度，此外还包括了比较强烈的难过情绪。这也表现了一贯支持火箭队的中国球迷以及粉丝对莫雷这一行为的不解和难以接受的态度



我们还根据用户言论计算得到了参与该话题讨论的用户的社会态度指标得分，如下图所示。经观察我们可以发现在对国家和地方政府的信心以及对经济的态度上参与话题讨论的用户同基准水平相比均没有太大差异，这也和此事件的性质相符，因为此事件本质上同政府行为无关。而在社会公平满意度这一指标上，参与莫雷事件讨论的网络大V的得分显著低于普通用户和基准水平，这说明微博上关注莫雷事件的意见领袖往往对社会公平更为敏感，对社会公平状况不满。

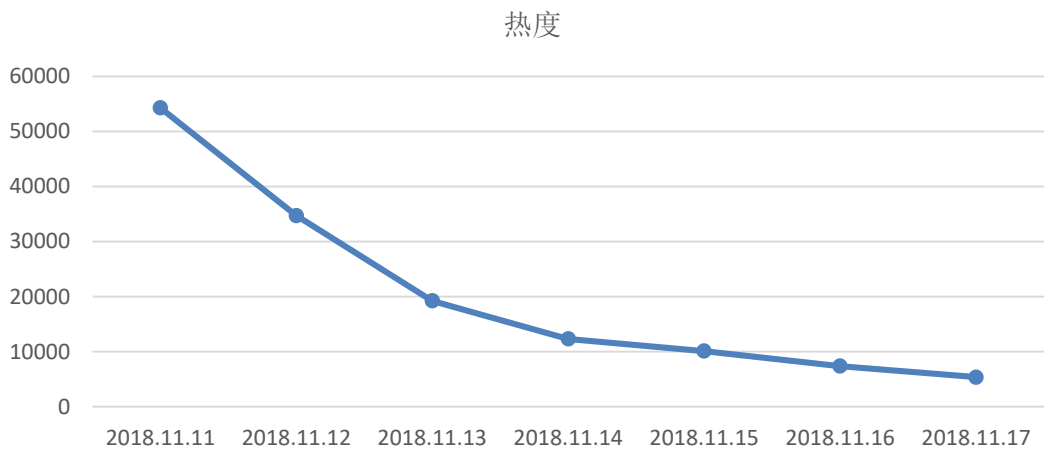


我们还计算了参与话题讨论的用户的大五人格得分，具体得分情况以及与基准用户的参照情况如下图所示（此处的基准用户得分为所下载的110万用户的大五人格得分均值，下同）。经观察我们可以发现参与莫雷事件讨论的用户在开放性维度上高于基准用户，也表明积极参与莫雷事件关注度其兴趣范围往往更为广泛，也更具有好奇心。

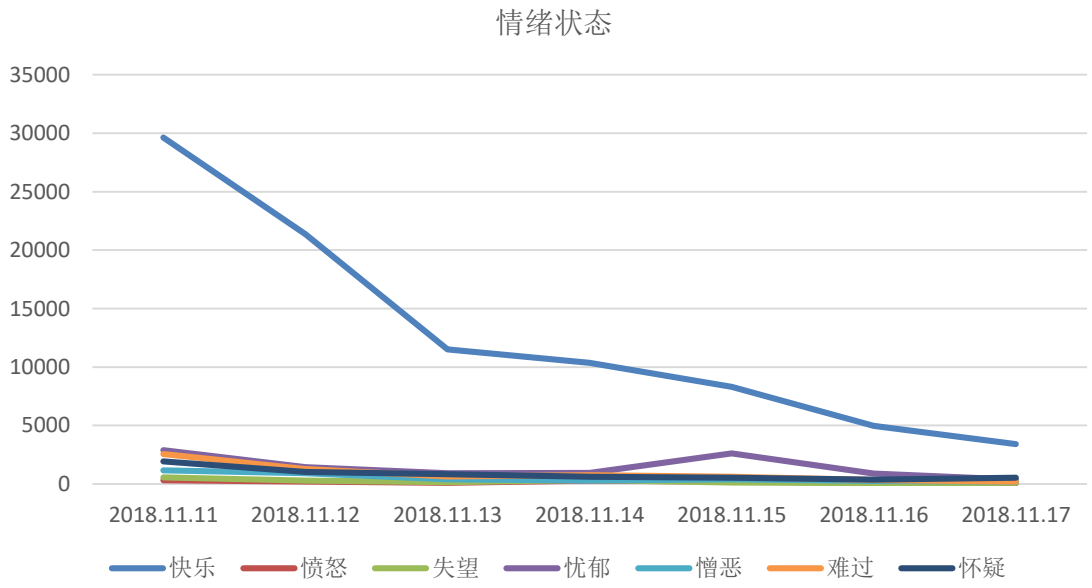


2018双十一

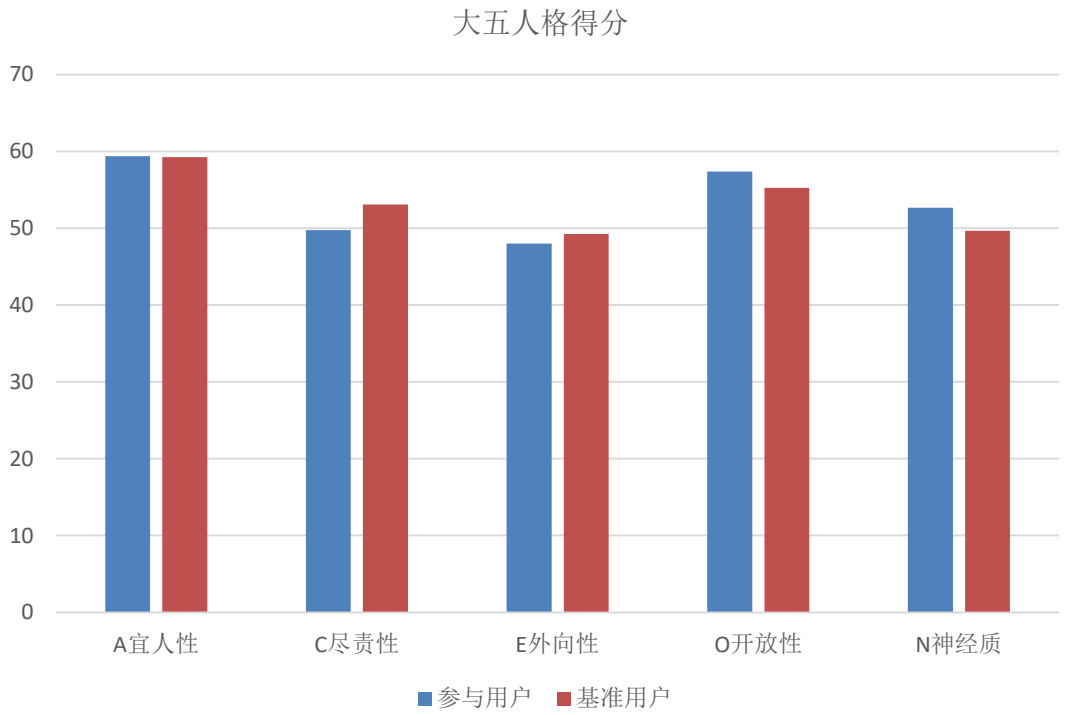
在2018年双十一事件中我们经计算发现参与该话题讨论的微博条数共有143436条，在一周的观察周期内具体的发博条数变化如下图所示。



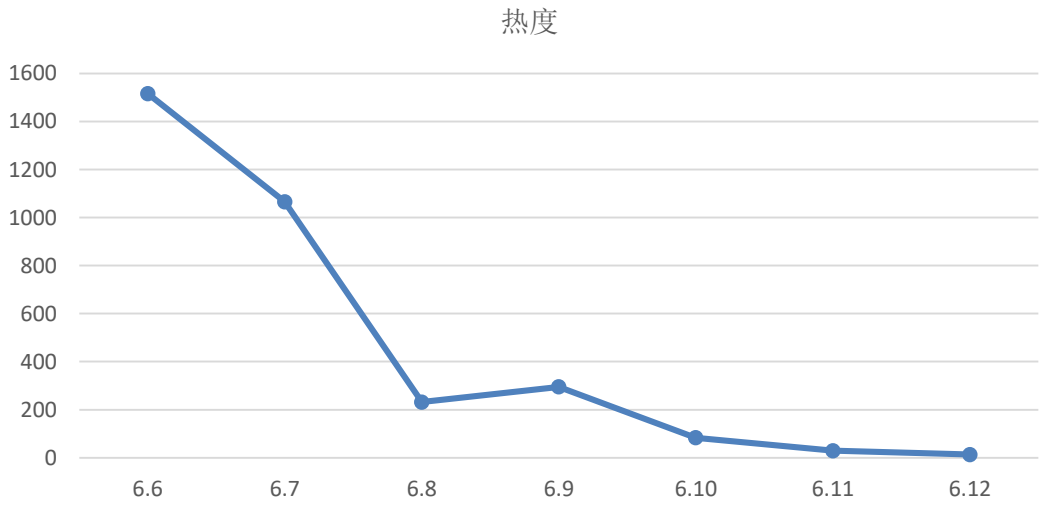
通过对用户发布的事件相关微博的言论分析，我们得到了在事件发生一周内用户的情绪分布状况，如下图所示。经观察我们可以发现其和话题的讨论热度发展趋势基本一致，用户的情绪也是在事件发生当天达到了最高点，之后随着活动结束而逐渐降低。其中大部分用户表达了快乐的情绪，特别是从一周的整个时间段来看，快乐的情绪都是明显占据主导地位，也表明了人们在参与双十一购物时的愉悦的心情。而在11.15这一天，忧郁的情绪有了小幅上升，我们猜想这或许同双十一产生的不理智消费有关。



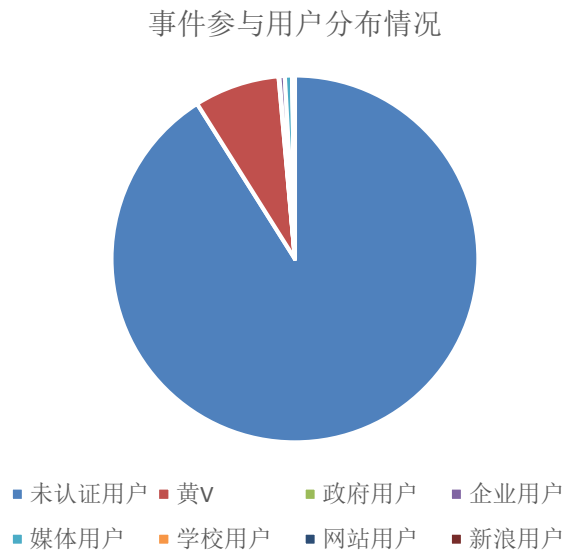
我们还计算了参与话题讨论的用户的大五人格得分，具体得分情况以及与基准用户的参照情况如下图所示。经观察可发现，参与双十一话题讨论的人相较于基准用户，在开放性、神经质维度上得分更高，而在尽责性维度上得分较低。这一结果表明积极参与双十一讨论的用户往往更具有好奇心，然而更易冲动，在自律性上表现较差。



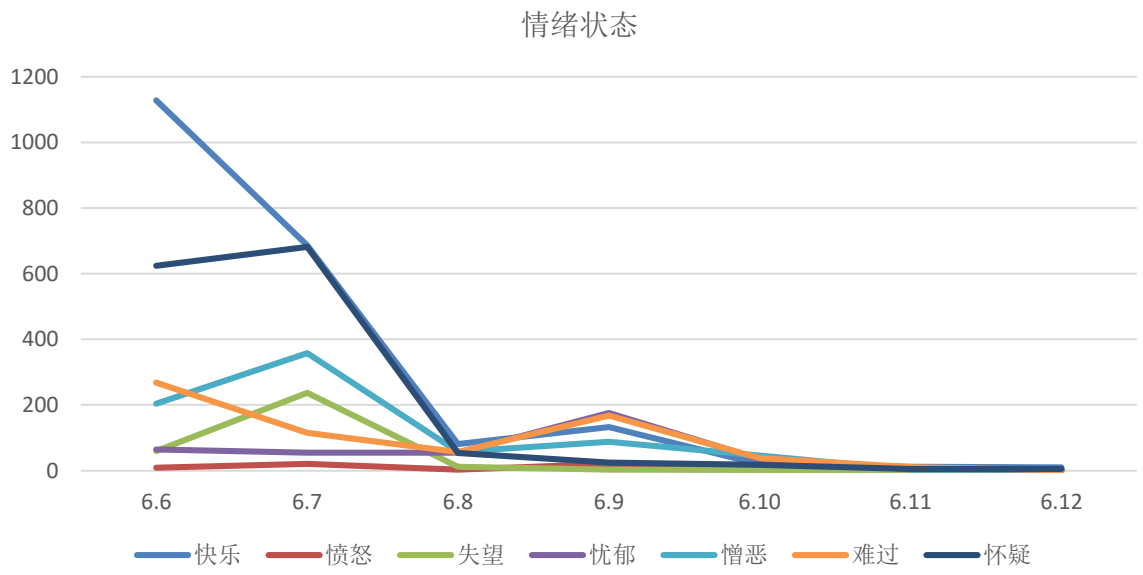
在林志玲结婚事件中我们经计算发现参与该话题讨论的微博条数共有3234条，在一周的观察周期内具体的发博条数变化如下图所示。



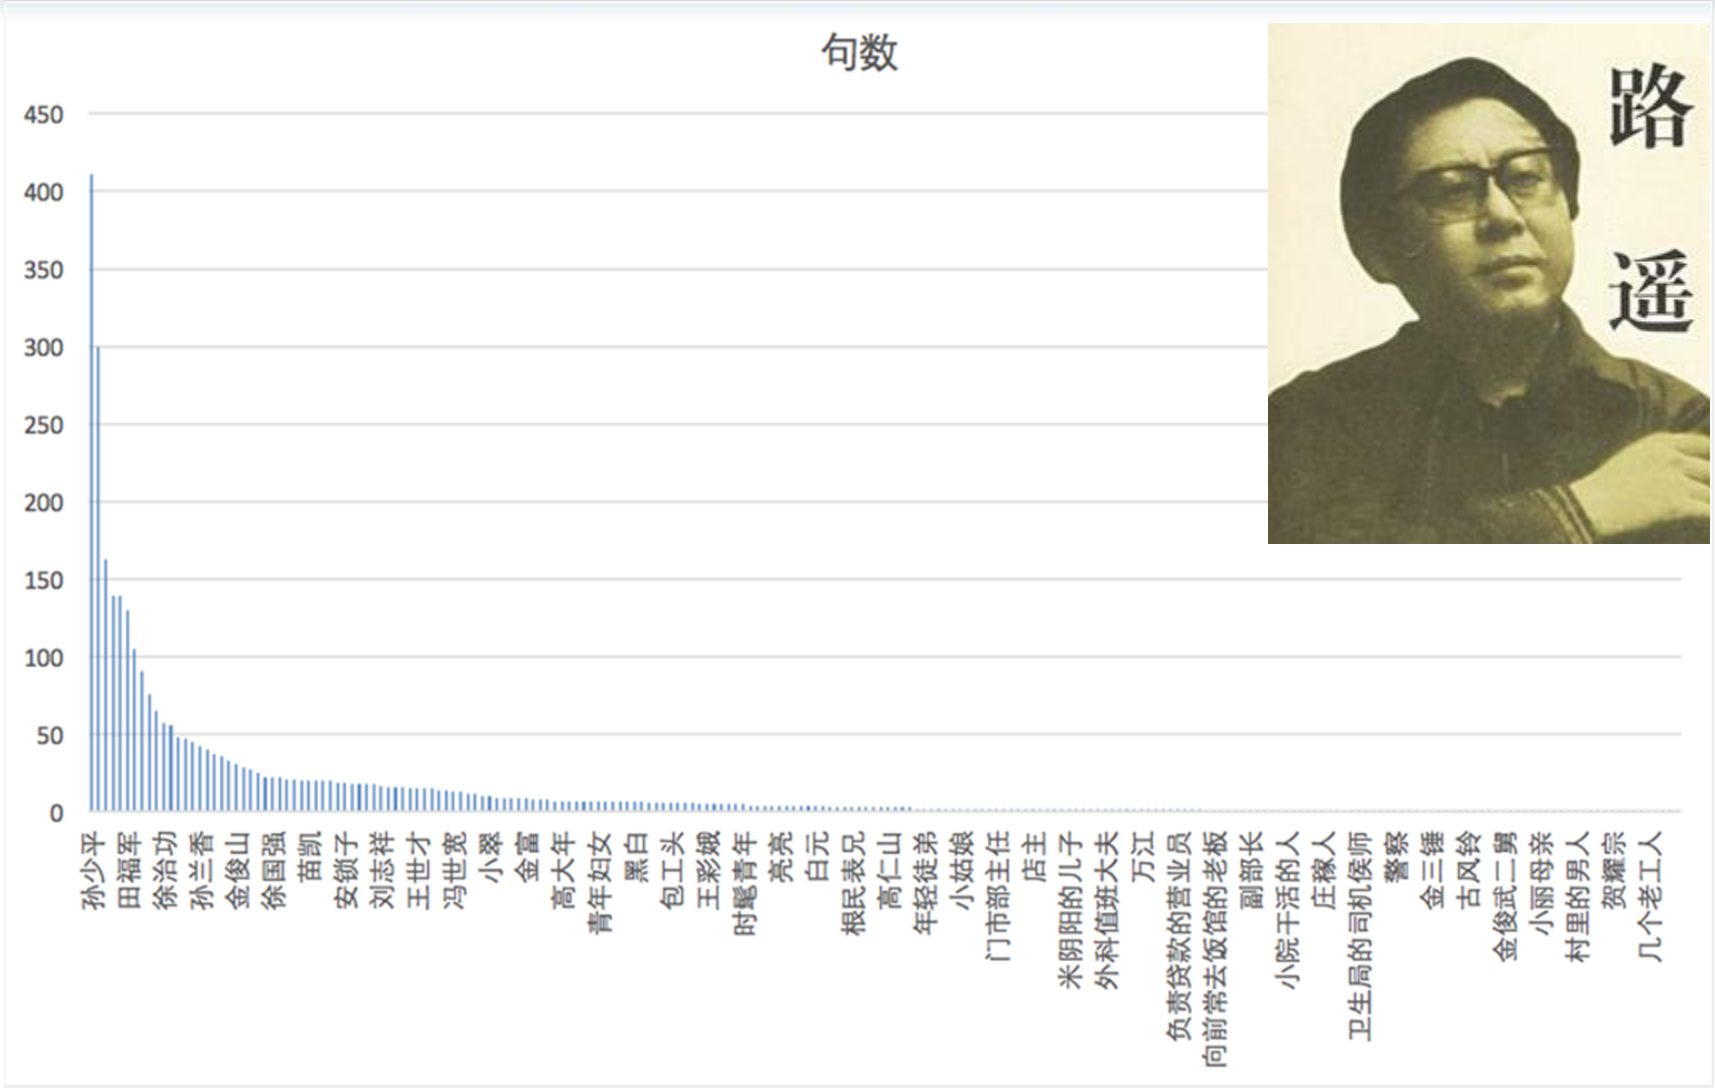
参与林志玲结婚事件讨论的人数共有2949人，其中普通用户占据了最大的比例，为91%；而发言的黄V用户的人数为222人，占到了总参与人数的8%。黄V用户占比较高也说明了在其在林志玲结婚消息中主动承担了一部分的宣传作用，扩大了消息的范围。



通过对用户发布的事件相关微博的言论分析，我们得到了在事件发生一周内用户的情绪分布状况，如下图所示。经观察我们可以发现在结婚消息公布之初参与话题讨论的用户的情绪以快乐为主，此外怀疑的声音也颇多。这表明了人们在祝贺林志玲结婚快乐的同时也有一部分人对这突如其来的消息的真实性产生了质疑。而之后由于话题的时效性，人们对该事件的关注度降低，各种情绪也大致处于下降趋势。



《平凡的世界》小说人物人格分析



主要人物的人格特征（时代特点）

姓名	A宜人性	C尽责性	E外向性	O开放性	N神经质
孙少安	67.91	84.23	94.13	81.97	75.61
孙少平	59.55	88.81	84.89	96.94	66.79
田润叶	62.66	96.00	95.00	73.76	63.78
田晓霞	72.49	66.08	82.52	94.35	61.03
平均数(标准差)	65.65(4.95)	83.78(11.05)	89.13(5.50)	86.76(9.39)	66.80(5.48)

吴育锋,吴胜涛,朱廷劭,刘洪飞,焦冬冬. 小说人物性格的文学智能分析: 以《平凡的世界》为例[J]. 中文信息学报, 2018, 32(7): 128-136.

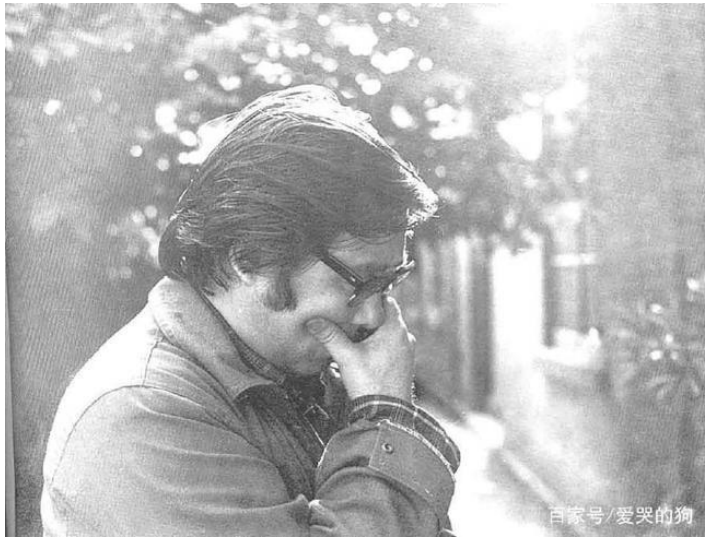
主要人物在重大生活事件前后的人格变化

姓名		A宜人性	C尽责性	E外向性	O开放性	N神经质
孙少安	结婚前	81.27233	85.83807	95.54907	88.55042	60.86471
	结婚后	60.68942	83.37657	93.35589	78.37709	83.58521
孙少平	高中毕业前	50.8893	82.69174	53.24782	89.93696	77.8545
	高中毕业后	62.17855	90.67123	94.46561	99.03313	63.43671

Mingming Liu, Yufeng Wu, Dongdong Jiao, Michael Shengtao Wu, Tingshao Zhu; Literary intelligence analysis of novel protagonists' personality traits and development, *Digital Scholarship in the Humanities*, , fqy020, https://doi.org/10.1093/llc/fqy020

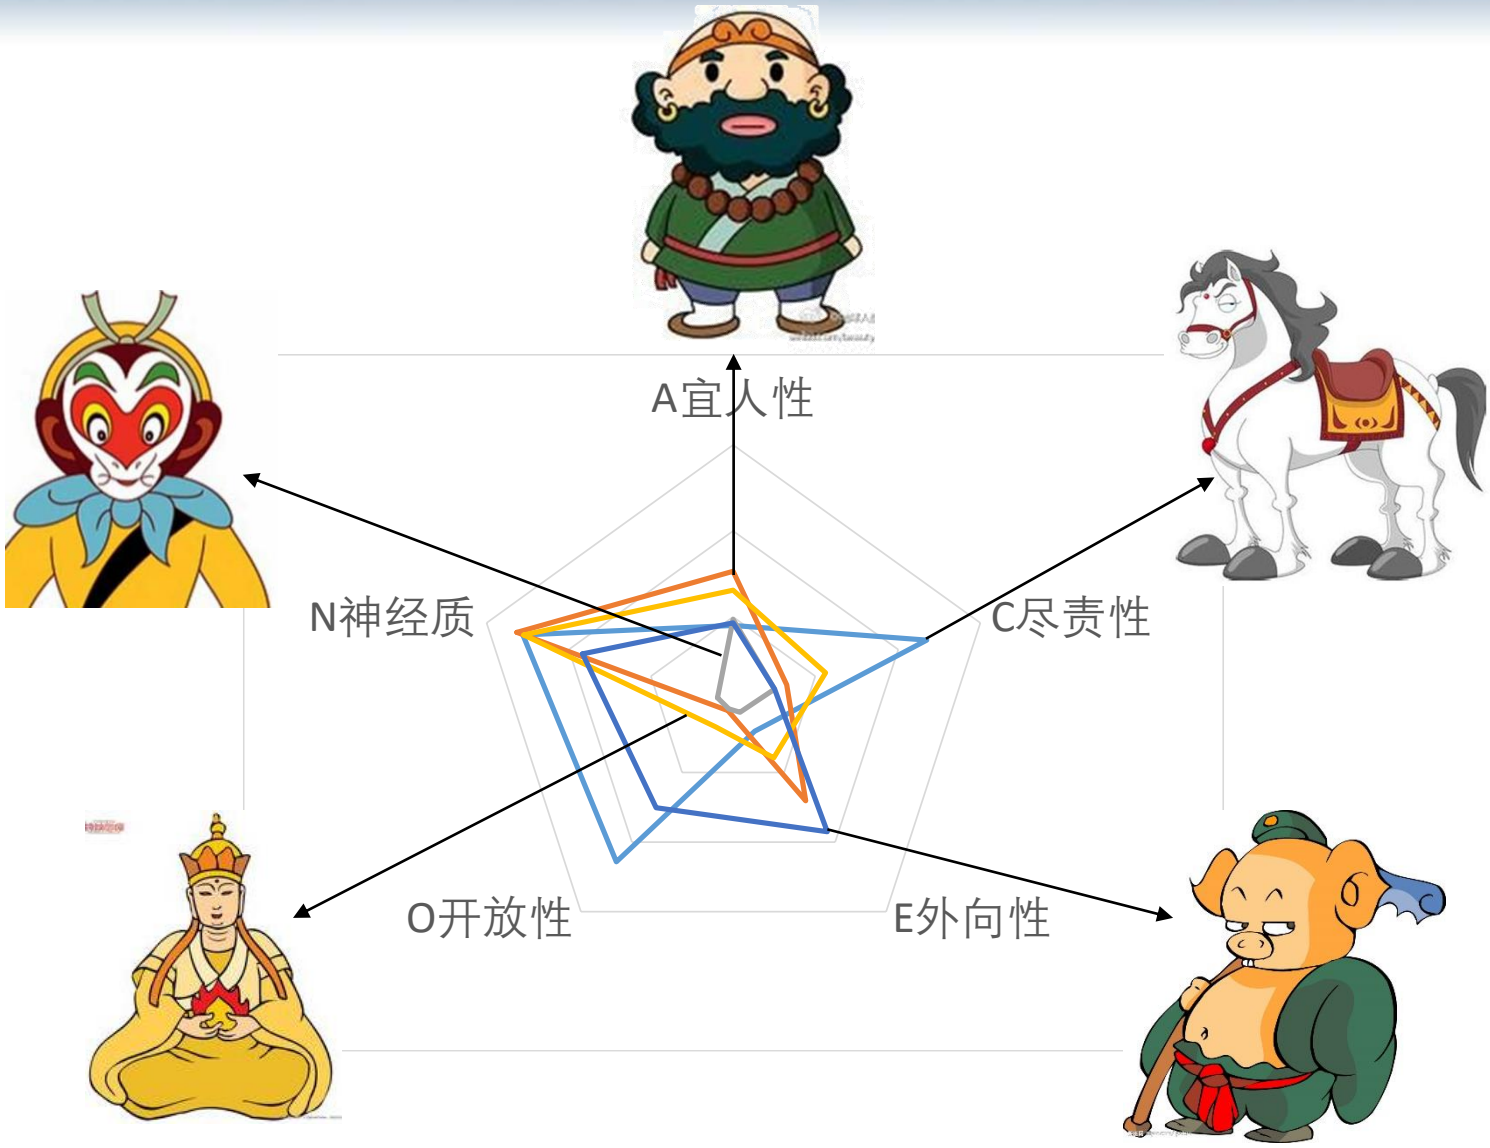
文学人物心理特点的解读

作家对文学人物心理特点的安排，与作家本人的生活经历密切相关：

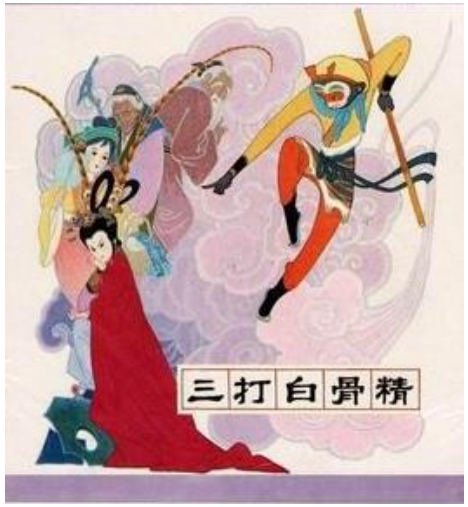


- 终生与贫穷为伴。生活窘境以及少年时期独特的心理历程；
- 婚姻不幸，深深陷于夫妻感情破裂的深谷之中不能自拔（孙少安的婚姻）；
- 对社会底层特别是奋斗青年，以永远的感情共鸣与精神鼓励（孙少平的求学）。

Personality of master and his prentices



Sun Wukong's Personality Changes



The big five of Sun Wukong before and after his beating the White Bone Demon for three times.

	agreeableness	conscientiousness	extraversion	openness	neuroticism
before	6.28	3.63	2.83	19.27	6.62
after	10.56	4.99	0.39	1.03	1.19

Thank You !



中国科学院心理研究所计算网络心理实验室

http://ccpl.psych.ac.cn